Studi Ablasi RNN, LSTM, dan GRU dibandingkan ANN untuk Prediksi Trafik Seluler Kota Milan

Adif Dafa Raihan
NIM 124400055
Teknik Telekomunikasi, ITERA
adif.124400055@student.itera.ac.id

Cindy Auliya
NIM 124400045
Teknik Telekomunikasi, ITERA
cindy.124400045@student.itera.ac.id

Bima Cahya Ramadhan
NIM 124400001
Teknik Telekomunikasi, ITERA
bima.124400001@student.itera.ac.id

Abstract*—Pertumbuhan trafik internet seluler menuntut operator meramalkan beban setiap sel secara akurat agar kapasitas dan energi jaringan dialokasikan secara efisien. Penelitian ini membandingkan ANN dengan RNN, LSTM, dan GRU untuk prediksi trafik per jam pada dataset Telecom Italia Big Data Challenge di Milan, dengan lokasi utama Duomo (kotak 5060) dan uji generalisasi di Navigli (kotak 4555). Kami melakukan studi ablasi terkontrol dengan mengubah satu faktor setiap kali, yaitu panjang jendela, ukuran hidden, jumlah lapisan, learning rate, kelompok fitur, dropout, dan horizon, masing-masing dengan tiga random seed. Konfigurasi dipilih hanya berdasarkan val MAE, lalu diuji pada minggu test dan periode Natal. Pada konfigurasi acuan, RNN memberikan test MAE terbaik (229,6 $\pm$ 5,1) dan mengungguli baseline naif minggu lalu (467,6), sedangkan ANN terlemah di antara empat model (309,9 $\pm$ 5,9). Penyetelan menurunkan MAE RNN menjadi 224,5 dan LSTM dari 273,6 menjadi 225,3, tetapi konfigurasi terbaik GRU justru memburuk (239,7 versus 237,2) karena overfit. Di Navigli urutan berubah dan ANN menjadi terbaik (191,1 $\pm$ 1,9). Hasil ini menunjukkan bahwa keunggulan model sekuensial bergantung pada lokasi dan bahwa pemilihan hyperparameter berbasis validasi tidak selalu menjamin perbaikan pada data uji.

***Index Terms*—prediksi trafik seluler, RNN, LSTM, GRU, studi ablasi**

I. Pendahuluan

Pertumbuhan trafik data seluler menuntut operator meramalkan permintaan tiap sel secara akurat untuk alokasi kapasitas, efisiensi energi, dan kualitas layanan. Peramalan yang terlalu rendah menyebabkan kongesti, sedangkan peramalan yang terlalu tinggi membuang kapasitas. Karena trafik mengikuti ritme harian, mingguan, dan karakter kawasan, model perlu menangkap dependensi temporal, bukan hanya hubungan antarfitur pada satu waktu.

ANN meratakan jendela observasi sehingga urutan waktu hilang. Recurrent neural network (RNN) mempertahankan hidden state, tetapi rentan terhadap vanishing gradient. Long short-term memory (LSTM) menambahkan gerbang input, forget, dan output serta cell state [1], sedangkan gated recurrent unit (GRU) menyederhanakannya menjadi gerbang reset dan update [2]. Keunggulan model sekuensial tidak otomatis karena bergantung pada panjang jendela, kapasitas hidden, kedalaman, learning rate, fitur, regularisasi, dan horizon. Studi ablasi yang mengubah satu faktor setiap kali memisahkan pengaruh faktor tersebut dari variasi antar-seed.

Kontribusi laporan ini ada tiga. Pertama, ablasi terkontrol lima faktor utama (panjang jendela, ukuran hidden, jumlah lapisan, learning rate, kelompok fitur) dan dua faktor tambahan (dropout, horizon) pada empat model dengan tiga seed di Duomo. Kedua, pemilihan konfigurasi hanya dari val MAE, lalu evaluasi pada minggu test dan Natal bersama baseline naif. Ketiga, uji generalisasi konfigurasi acuan dan terbaik di Navigli (kotak 4555, kode 1).

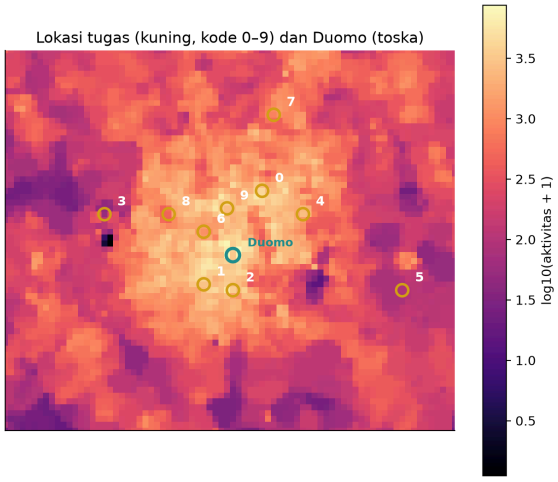


Fig. 1. Rata-rata aktivitas internet per kotak di Milan. Lingkaran kuning menunjukkan lokasi tugas (kode 0–9); lingkaran toska menunjukkan Duomo.

II. Data dan Metode

A. Dataset

Data berasal dari Telecom Italia Big Data Challenge [3] yang mencakup aktivitas jaringan di Kota Milan, Italia. Kami memakai versi agregasi per jam [4] untuk periode 4 November–29 Desember 2013, sehingga setiap lokasi memiliki 1.344 observasi atau 56 hari. Setiap catatan memuat tiga kanal trafik, yaitu internet (net), panggilan (call), dan SMS (sms). Fitur masukan berjumlah tujuh: net, call, sms, serta empat fitur waktu berupa sinus dan kosinus jam (jam_sin, jam_cos) dan hari (hari_sin, hari_cos). Fitur waktu merepresentasikan periodisitas sirkadian dan mingguan secara kontinu. Target peramalan adalah net satu jam ke depan.

Lokasi utama penelitian adalah kotak Duomo 5060 yang mewakili pusat aktivitas kota. Sebagai uji generalisasi, kami memakai lokasi kelompok, yaitu Navigli (Darsena) pada kotak 4555 dengan kode lokasi 1. Sebaran kedua lokasi ditunjukkan pada Fig. 1.

B. Pembagian Data dan Praproses

Pembagian data dilakukan secara kronologis: train 11 November–8 Desember 2013 (672 jam), validasi 9–15 Desember, test 16–22 Desember, dan periode Natal 23–29 Desember. Minggu pertama, 4–10 November, tidak dipakai sebagai sampel latih dan hanya menjadi konteks jendela bagi sampel awal. Pembagian ini memisahkan masa depan dari masa lalu sehingga tidak ada informasi test yang bocor ke pelatihan.

Standardisasi z-score dihitung dari rata-rata dan simpangan baku data sebelum 9 Desember, yaitu data latih beserta minggu konteks. Statistik tersebut kemudian diterapkan pada validasi, test, dan Natal. Dengan cara ini, model tidak pernah melihat statistik periode evaluasi. Jendela masukan dibentuk dengan panjang $W = 24$ jam dan horizon $H = 1$ jam, sehingga terdapat 672 jendela latih. Sebuah jendela dimasukkan ke split tertentu berdasarkan waktu targetnya, bukan waktu awal jendela. Prediksi dikembalikan ke skala asli sebelum metrik dihitung.

Data deret waktu tidak diacak pada tahap pembagian karena pengacakan akan mencampur masa lalu dan masa depan serta merusak urutan yang menjadi objek peramalan. Pengacakan hanya dilakukan pada urutan mini-batch selama pelatihan; setiap jendela tetap mempertahankan urutan internalnya.

C. Model dan Konfigurasi Acuan

ANN meratakan jendela $W \times 7$ menjadi vektor dan memetakannya melalui dua lapisan tersembunyi berukuran 32 dengan aktivasi ReLU. Model ini tidak memodelkan urutan secara eksplisit. RNN sederhana memproses jendela langkah demi langkah dengan hidden state berukuran 68 dan memakai state terakhir untuk prediksi. LSTM memakai hidden state 33 serta tiga gerbang dan cell state [1], sedangkan GRU memakai hidden state 38 dengan dua gerbang [2]. Pada ketiga model rekuren, keluaran diambil dari hidden state langkah terakhir, lalu dilewatkan satu lapisan linear.

Semua model dilatih dengan fungsi loss MSE dan optimizer Adam (learning rate 10^{-3}), batch 64, serta early stopping pada val MSE dengan patience 30 dan maksimum 300 epoch. Bobot terbaik dipilih dari epoch dengan val MSE terendah. Pelatihan diimplementasikan dengan PyTorch [5]. Konfigurasi acuan dirangkum pada Tabel I.

D. Protokol Ablasi dan Evaluasi

Setiap eksperimen mengubah satu faktor dari konfigurasi acuan, sedangkan faktor lain dipertahankan. Faktor A1 menguji panjang jendela $W \in \{6, 12, 24, 48, 168\}$ jam; A2 ukuran hidden $\{16, 32, 64, 128\}$; A3 jumlah lapisan $\{1, 2, 3\}$; A4 learning rate $\{10^{-4}, 10^{-3}, 10^{-2}\}$; dan A5 kelompok fitur {net, net+call+sms, net+waktu, semua}. Dua faktor tambahan adalah B2 dropout {0; 0,2; 0,5} dan B6 horizon {1, 6, 24} jam. Setiap konfigurasi dilatih dengan tiga random seed, yaitu 0, 1, dan 2, lalu dilaporkan sebagai rata-rata $\pm$ simpangan baku.

Evaluasi memakai MAE, RMSE, dan MAPE pada skala asli. MAE menjadi metrik utama karena satuannya sama dengan aktivitas trafik, sedangkan MAPE memberi gambaran error relatif. Pemilihan konfigurasi terbaik hanya memakai val MAE; data test dan Natal tidak dipakai sampai evaluasi akhir. Konfigurasi terbaik tiap model kemudian digabungkan pada Bagian C dan diuji generalisasinya pada Bagian D.

TABLE I
KONFIGURASI ACUAN DAN JUMLAH PARAMETER

Hyperparameter	**Nilai acuan**
Panjang jendela W	24 jam
Horizon	1 jam
Ukuran hidden	ANN 32, RNN 68, LSTM 33, GRU 38
Jumlah lapisan	ANN 2, rekuren 1
Fitur	net, call, sms, jam (sin/cos), hari (sin/cos) — 7 fitur
Jumlah parameter	ANN 6.497, RNN 5.305, LSTM 5.578, GRU 5.397
Optimizer, *learning rate*	Adam, 10^{-3}
Batch size	64
Early stopping	*patience* 30, maks. 300 epoch

Seluruh pelatihan dijalankan pada CPU dengan PyTorch. Sebanyak 270 pelatihan unik (348 catatan run karena beberapa konfigurasi acuan dipakai ulang) memerlukan total waktu 92,6 menit.

III. HASIL

A. Bagian 0 — Baseline Naif dan Model Acuan

Evaluasi diawali dengan membandingkan performa model deep learning pada konfigurasi acuan terhadap tiga metode baseline naif tanpa parameter di lokasi Duomo (kotak 5060) dengan horizon peramalan satu jam ($H = 1$). Tiga baseline naif yang diuji mencakup:

1) **Naif nilai terakhir** (*persistence*, $\hat{y}_t = y_{t-1}$), yang mengasumsikan trafik satu jam ke depan identik dengan nilai satu jam sebelumnya;
2) **Naif kemarin** ($\hat{y}_t = y_{t-24}$), yang memanfaatkan siklus harian (sirkadian 24 jam); serta
3) **Naif minggu lalu** ($\hat{y}_t = y_{t-168}$), yang memproyeksikan aktivitas trafik pada jam yang sama di hari yang sama pada minggu sebelumnya.

Hasil komparasi kinerja baseline naif dan empat arsitektur deep learning acuan (ANN, RNN, LSTM, GRU) disajikan pada Tabel II. Seluruh nilai model acuan dilaporkan sebagai rata-rata $\pm$ simpangan baku dari tiga *random seed* (0, 1, 2).

a) *Performa pada Kondisi Reguler (Minggu Test):*

Pada periode evaluasi normal (minggu test 16–22 Desember 2013), metode baseline naif menunjukkan bahwa trafik seluler memiliki ketergantungan musiman yang kuat. Baseline naif minggu lalu menjadi metode nirparameter terkuat dengan test MAE 467,6, mengungguli naif kemarin (552,2) dan naif nilai terakhir (600,9). Hal ini mengonfirmasi bahwa pola hari kerja versus akhir pekan berulang secara reguler pada skala mingguan di pusat perkantoran Duomo.

Kendati demikian, seluruh model deep learning mampu mengungguli baseline naif terbaik secara signifikan. Model ANN acuan menurunkan test MAE menjadi 309,9 $\pm$ 5,9

TABLE II
BASELINE NAIF DAN KONFIGURASI ACUAN DI DUOMO ($H = 1$ JAM, RATA-RATA $\pm$ SIMPANGAN BAKU, 3 SEED)

Metode / Model	Param	Val MAE	Test MAE	Test MAPE	Natal MAE
Naif: nilai terakhir	0	662,6	600,9	18,4%	431,2
Naif: kemarin	0	595,3	552,2	23,8%	921,5
Naif: minggu lalu	0	492,8	467,6	19,9%	1.426,2
ANN (Acuan)	6.497	248,9 $\pm$ 8,9	309,9 $\pm$ 5,9	11,3 $\pm$ 0,8%	680,1 $\pm$ 52,0
RNN (Acuan)	5.305	206,1 $\pm$ 7,4	229,6 $\pm$ 5,1	8,5 $\pm$ 0,3%	421,2 $\pm$ 2,4
LSTM (Acuan)	5.578	230,5 $\pm$ 12,2	273,6 $\pm$ 25,4	9,1 $\pm$ 1,0%	586,0 $\pm$ 56,8
GRU (Acuan)	5.397	207,5 $\pm$ 3,8	237,2 $\pm$ 9,3	8,0 $\pm$ 0,7%	468,2 $\pm$ 21,8

(turun 33,7% dari naif minggu lalu). Ketiga arsitektur rekuren menunjukkan keunggulan yang lebih tajam: LSTM mencapai test MAE 273,6 $\pm$ 25,4 (turun 41,5%), GRU mencapai 237,2 $\pm$ 9,3 (turun 49,3%), dan Simple RNN mencatatkan kesalahan terendah sebesar 229,6 $\pm$ 5,1 (turun 50,9%). Keunggulan telak model rekuren dibanding ANN membuktikan bahwa mekanisme memori sekuensial langkah demi langkah jauh lebih efektif menangkap lintasan temporal dibanding sekadar meratakan matriks jendela observasi $W \times 7$ menjadi satu vektor input pada feedforward ANN.

b) *Analisis MAPE (*Mean Absolute Percentage Error*):*

Metrik MAPE memberikan gambaran kesalahan relatif terhadap fluktuasi magnitudo trafik asli. Pada metode naif, MAPE berkisar antara 18,4% (nilai terakhir) hingga 23,8% (kemarin). Naif kemarin mengalami persentase kesalahan tertinggi karena pergeseran fasa jam antarhari sering memicu error relatif besar pada jam-jam sepi (dini hari).

Sebaliknya, seluruh model deep learning memangkas batas MAPE ke kisaran 8,0%–11,3%. GRU menghasilkan test MAPE paling presisi yaitu **8,0 $\pm$ 0,7%**, diikuti oleh RNN (8,5 $\pm$ 0,3%), LSTM (9,1 $\pm$ 1,0%), dan ANN (11,3 $\pm$ 0,8%). Keunggulan GRU pada metrik persentase mengindikasikan bahwa struktur gerbang *reset* dan *update* miliknya sangat adaptif dalam menjaga proporsi simpangan yang stabil di seluruh kontur kurva beban, baik pada saat trafik mencapai lembah di malam hari maupun puncak pada jam sibuk siang hari.

c) *Perilaku pada Anomali Minggu Natal:*

Minggu Natal (23–29 Desember 2013) menjadi pengujian ekstrem atas ketahanan model terhadap pergeseran distribusi temporal (*distribution drift*). Karena kawasan Duomo merupakan pusat perkantoran, perbankan, dan komersial, perayaan malam dan hari Natal (24–26 Desember) memicu penurunan aktivitas kerja yang sangat tajam dibanding hari kerja normal.

Perubahan pola struktural ini menyebabkan baseline naif berbasis kalender mengalami kehancuran katastropik:

1) **Naif minggu lalu** runtuh total dengan lonjakan MAE lebih dari 200% menjadi **1.426,2** (MAPE melonjak mendekati 97%). Metode ini salah memproyeksikan beban kerja padat dari minggu sebelumnya ke hari libur perayaan Natal.
2) **Naif kemarin** turut mengalami degradasi parah hingga MAE **921,5** (MAPE 42,2%) saat transisi hari normal ke hari libur berlangsung.
3) Sebaliknya, **naif nilai terakhir** justru membaik menjadi MAE **431,2** (lebih rendah dibanding performa test regulernya 600,9). Ketika aktivitas masyarakat surut dan pola trafik bertahan pada level rendah yang datar, persistensi sesaat $(t-1)$ tidak terjebak oleh asumsi musiman mingguan yang keliru.

Bagi model deep learning, tidak adanya sampel hari libur dalam data latih (11 November–8 Desember) menyebabkan seluruh model mengalami kenaikan error. Namun, arsitektur rekuren memperlihatkan daya tahan yang jauh lebih tinggi daripada ANN:

- **Simple RNN (Acuan)** menjadi model paling tangguh dengan Natal MAE terendah sebesar **421,2 $\pm$ 2,4** (bahkan mengungguli seluruh baseline naif, termasuk naif nilai terakhir 431,2, serta memiliki variansi antar-seed terkecil $\pm 2,4$).
- **GRU (Acuan)** menyusul di peringkat kedua dengan Natal MAE **468,2 $\pm$ 21,8**.
- Sebaliknya, **LSTM** (586,0 $\pm$ 56,8) dan **ANN** (680,1 $\pm$ 52,0) menderita degradasi drastis. Tingginya lonjakan error pada ANN disebabkan oleh ketergantungannya pada bobot statis fitur kalender (hari dalam seminggu) yang memaksakan keluaran trafik tinggi pada hari Selasa–Kamis kalender, padahal realitas aktivitas perkantoran Duomo sedang tutup total untuk libur akhir tahun.

B. Bagian A — Ablasi Wajib

Pada bagian ini, dilakukan studi ablasi terkontrol menggunakan protokol *one-factor-at-a-time* (OFAT). Setiap subbagian (A1 hingga A5) hanya memvariasikan tepat satu faktor hiperparameter secara terisolasi, sementara seluruh faktor lainnya dibekukan pada nilai konfigurasi acuan (Tabel I), yaitu $W = 24$ jam, horizon $H = 1$ jam, ukuran hidden acuan (ANN 32, RNN 68, LSTM 33, GRU 38), kedalaman acuan (ANN 2 lapis, rekuren 1 lapis), kelompok fitur lengkap (7 fitur), optimizer Adam dengan *learning rate* 10^{-3}, dan *batch size* 64. Setiap eksperimen dijalankan secara independen pada tiga *random seed* (0, 1, 2) untuk memisahkan dampak arsitektural dari variasi stokastik inisialisasi bobot dan pengacakan batch. Pemilihan konfigurasi terbaik didasarkan murni pada metrik *validation* MAE guna menghindari kebocoran informasi uji (*test data leakage*).

a) *A1. Pengaruh Panjang Jendela Observasi (W):*

Eksperimen A1 menguji pengaruh panjang konteks historis masukan dengan memvariasikan $W \in \{6, 12, 24, 48, 168\}$ jam (mencakup rentang dari seperempat hari hingga satu minggu penuh). Hasil pengukuran **test** MAE disajikan pada Tabel III; sel tebal menandai konfigurasi yang terpilih

berdasarkan val MAE. Tren perbandingannya diilustrasikan pada Fig. 2.

TABLE III
PENGARUH PANJANG JENDELA W (JAM) TERHADAP TEST MAE (RATA-RATA ± SD, 3 SEED). SEL TEBAL = KONFIGURASI TERPILIH BERDASARKAN VAL MAE.

W (jam)	ANN	RNN	LSTM	GRU
6	**269,4 ± 16,8**	228,6 ± 5,4	**276,4 ± 14,7**	249,8 ± 1,4
12	308,8 ± 11,6	233,2 ± 11,2	302,7 ± 17,4	246,1 ± 13,5
24	309,9 ± 5,9	229,6 ± 5,1	273,6 ± 25,4	237,2 ± 9,3
48	333,1 ± 20,2	**224,5 ± 11,7**	304,4 ± 27,1	**237,1 ± 10,6**
168	402,0 ± 12,5	233,5 ± 4,8	292,8 ± 20,0	237,2 ± 10,6

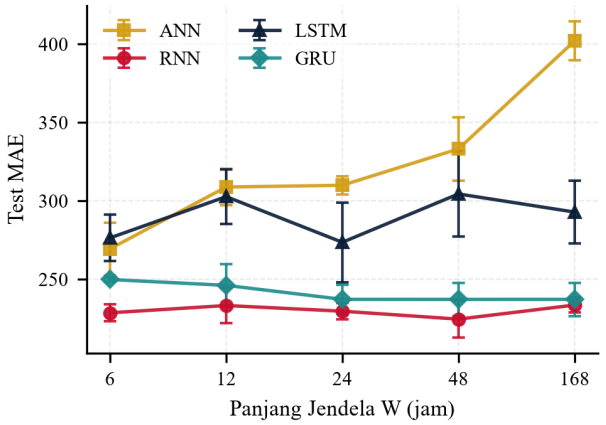


Fig. 2. Test MAE terhadap panjang jendela W untuk empat model di Duomo (rata-rata ± SD, 3 seed).

Dari hasil eksperimen terungkap tiga pola perilaku:

1) **Degradasi Monotonik pada Feedforward ANN:** Test MAE terendah ANN diraih pada $W = 6$ jam (269,4 ± 16,8) dan membengkak hingga 402,0 ± 12,5 pada $W = 168$ jam. Val MAE juga memilih $W = 6$ (211,5 ± 6,2). Karena ANN meratakan matriks jendela observasi, penambahan panjang jendela melipatgandakan jumlah parameter secara drastis, dari 2.465 parameter pada $W = 6$ menjadi 38.753 parameter pada $W = 168$ (input layer berdimensi $168 \times 7 = 1.176$). Pada 672 sampel latih, kondisi ini memicu *curse of dimensionality* dan overfitting.
2) **Ketahanan Jangka Panjang pada Model Rekuren:** Model rekuren memiliki jumlah parameter yang konstan terhadap W (RNN 5.305 dan GRU 5.397). Simple RNN dan GRU mencapai val MAE terbaik pada $W = 48$ jam, masing-masing 200,1 ± 5,3 dan 206,7 ± 5,0, dengan test MAE 224,5 ± 11,7 dan 237,1 ± 10,6. Pada $W = 168$, test MAE RNN (233,5 ± 4,8) dan GRU (237,2 ± 10,6) tetap stabil. Ini menunjukkan keunggulan pemrosesan sekuensial dalam memfilter sinyal deret panjang tanpa menambah kompleksitas bobot.
3) **Perilaku LSTM:** LSTM mencapai val MAE optimal pada $W = 6$ jam (227,1 ± 4,3), tetapi test MAE-nya 276,4 ± 14,7. Pada test, nilai terendah justru diperoleh $W = 24$ (273,6 ± 25,4), hanya berbeda 2,8 dari $W = 6$. Pada $W = 48$, variansi LSTM melebar hingga ± 27,1 akibat kesulitan optimasi tiga pasang gerbang pada sekuens panjang. Perbedaan kecil ini menunjukkan bahwa pemilihan berbasis val tidak selalu transfer sempurna ke test.

b) *A2. Pengaruh Ukuran Lapisan Tersembunyi (*Hidden Units*):*

Eksperimen A2 mengevaluasi kapasitas representasi dengan memvariasikan dimensi hidden state $\in \{16, 32, 64, 128\}$. Hasil val MAE dirangkum pada Tabel IV, sedangkan visualisasi dinamika performa dan dampaknya terhadap jumlah parameter disajikan pada Fig. 3 dan Fig. 4.

TABLE IV
PENGARUH UKURAN HIDDEN TERHADAP VAL MAE (RATA-RATA ± SD, 3 SEED)

Ukuran Hidden	ANN	RNN	LSTM	GRU
16	257,6 ± 28,0	247,0 ± 5,8	244,3 ± 18,3	216,8 ± 21,2
32	248,9 ± 8,9	218,7 ± 6,6	241,5 ± 20,5	210,2 ± 0,8
64	238,4 ± 16,5	**207,2 ± 12,8**	218,1 ± 1,9	198,4 ± 9,2
128	**233,8 ± 1,9**	207,7 ± 7,2	**207,1 ± 8,4**	**188,7 ± 4,2**

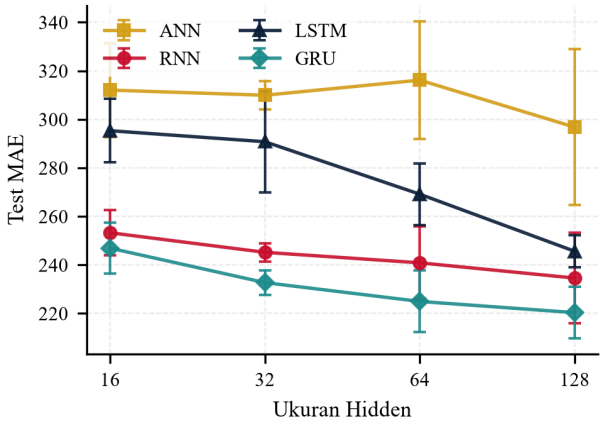


Fig. 3. Test MAE terhadap ukuran hidden di Duomo (rata-rata ± SD, 3 seed).

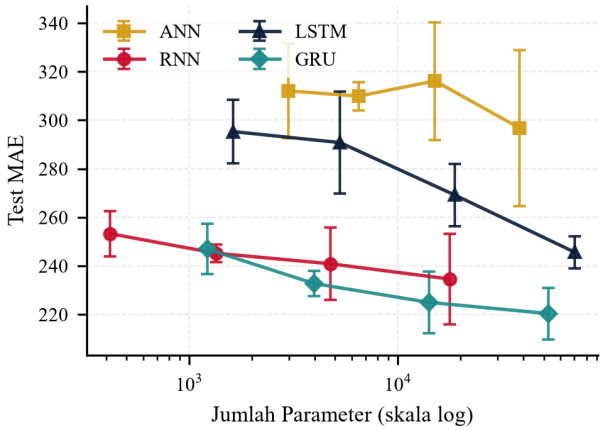


Fig. 4. Jumlah parameter model terhadap ukuran hidden untuk empat arsitektur.

Dampak kapasitas terhadap performa dan kompleksitas komputasi model dapat dianalisis sebagai berikut:

1) **Underfitting pada Kapasitas Rendah:** Ukuran hidden 16 menghasilkan kesalahan tertinggi pada seluruh model (val MAE ANN 257,6; RNN 247,0; LSTM 244,3; GRU 216,8). Kapasitas memori 16 unit terbukti terlalu sempit untuk mengekstraksi dinamika multivariat gabungan dari 7 fitur masukan.
2) **Penskalaan Kuadratik Parameter:** Jumlah parameter sel rekuren bertumbuh secara kuadratik terhadap ukuran hidden ($O(h^2)$). Pada hidden 128, parameter LSTM melonjak drastis hingga 70.273 parameter, GRU mencapai 52.737 parameter, ANN 38.273 parameter, dan Simple RNN 17.665 parameter.
3) **Keuntungan Kapasitas Besar dan Titik Jenuh:** Peningkatan hidden hingga 128 secara konsisten menurunkan val MAE pada semua arsitektur. GRU 128 mencetak skor validasi terendah di seluruh studi ablasi ($\mathbf{188,7 \pm 4,2}$; test MAE 220,3), diikuti LSTM 128 ($\mathbf{207,1 \pm 8,4}$; test MAE 245,6), dan ANN 128 ($\mathbf{233,8 \pm 1,9}$). Pada RNN, ukuran 64 unit ($207,2 \pm 12,8$) sudah mencapai titik jenuh, di mana pelipatgandaan ke 128 unit tidak memberikan penurunan error yang signifikan ($207,7 \pm 7,2$). Kendati kapasitas 128 unit memberi representasi non-linear yang sangat ekspresif, pembengkakan parameter ini meningkatkan risiko overfitting jika tanpa regularisasi.

c) *A3. Pengaruh Kedalaman Lapisan (*Number of Layers*):* Eksperimen A3 menguji kedalaman hierarki representasi dengan memvariasikan jumlah lapisan tersembunyi $\in \{1, 2, 3\}$. Hasil pengukuran disajikan pada Tabel V dan Fig. 5.

TABLE V
PENGARUH JUMLAH LAPISAN TERHADAP VAL MAE (RATA-RATA ± SD, 3 SEED)

Jumlah Lapisan	ANN	RNN	LSTM	GRU
1	**240,9 ± 7,5**	**206,1 ± 7,4**	**230,5 ± 12,2**	207,5 ± 3,8
2	248,9 ± 8,9	207,3 ± 9,1	254,8 ± 14,5	**203,3 ± 9,6**
3	244,9 ± 5,4	225,1 ± 12,7	338,9 ± 16,9	212,2 ± 15,9

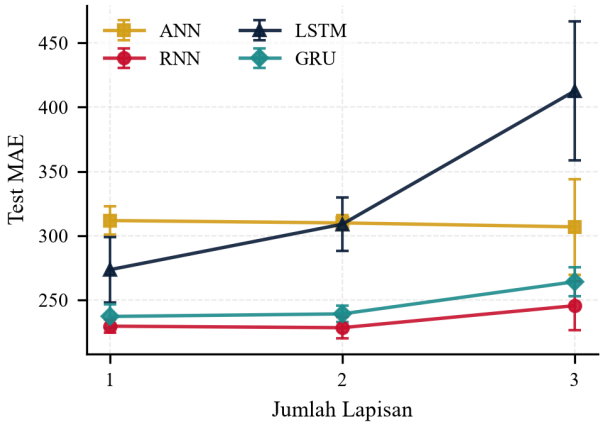


Fig. 5. Test MAE terhadap jumlah lapisan di Duomo (rata-rata ± SD, 3 seed).

Temuan krusial dari variasi kedalaman meliputi:

1) **Stabilitas Arsitektur Dangkal pada Feedforward ANN:** Penambahan lapisan ANN dari 1 ke 2 dan 3 lapis menghasilkan rentang val MAE yang hampir identik (240, 9 hingga 248, 9). Karena deret waktu ini berpusat pada target univariat tunggal, penumpukan lapisan feedforward tidak memberikan abstraksi hierarkis tambahan yang bermakna.
2) **Optimum Dangkal pada RNN dan GRU:** Simple RNN mencapai performa terbaik pada 1 lapisan rekuren ($206,1 \pm 7,4$), dan mulai mengalami peningkatan galat pada 3 lapisan ($225,1 \pm 12,7$). GRU meraih hasil terbaik pada 2 lapisan ($203,3 \pm 9,6$), sebelum terdegradasi pada 3 lapisan ($212,2 \pm 15,9$).
3) **Kasus Ekstrem Kegagalan LSTM Tiga Lapis:** Fenomena paling mencolok terjadi pada arsitektur LSTM, di mana penambahan kedalaman menjadi 3 lapisan memicu degradasi performa yang katastropik. Val MAE LSTM melonjak drastis dari $\mathbf{230,5 \pm 12,2}$ (1 lapis) menjadi $\mathbf{338,9 \pm 16,9}$ (3 lapis), sementara Test MAE anjlok ke level **412,6**. Fenomena ini disebabkan oleh hambatan propagasi balik gradien (*vanishing gradients*) yang berlipat ganda saat melintasi tiga tumpukan gerbang rekuren tanpa jalur koneksi *skip-connection* / residual. Dikombinasikan dengan ukuran dataset latih yang terbatas (672 jam), model 3-lapis LSTM terjebak dalam minimum lokal yang buruk. Hal ini membuktikan bahwa untuk peramalan trafik seluler berskala data moderat, model rekuren berarsitektur dangkal (1–2 lapis) jauh lebih unggul

dan mudah dilatih dibanding jaringan dalam (*deep recurrent networks*).

d) *A4. Pengaruh Laju Pembelajaran (*Learning Rate*):* Eksperimen A4 menguji stabilitas dan kecepatan konvergensi terhadap learning rate optimizer Adam dengan variasi $\texttt{lr} \in \{10^{-4}, 10^{-3}, 10^{-2}\}$. Hasil val MAE dirangkum pada Tabel VI, dan dinamika performa divisualisasikan pada Fig. 6.

TABLE VI
PENGARUH LEARNING RATE TERHADAP VAL MAE (RATA-RATA ± SD, 3 SEED)

Learning Rate	ANN	RNN	LSTM	GRU
10^{-4}	295,3 ± 4,6	285,0 ± 13,7	399,4 ± 25,0	398,4 ± 8,6
10^{-3}	**248,9 ± 8,9**	**206,1 ± 7,4**	230,5 ± 12,2	**207,5 ± 3,8**
10^{-2}	261,8 ± 16,6	226,7 ± 6,7	**215,9 ± 14,2**	208,2 ± 5,6

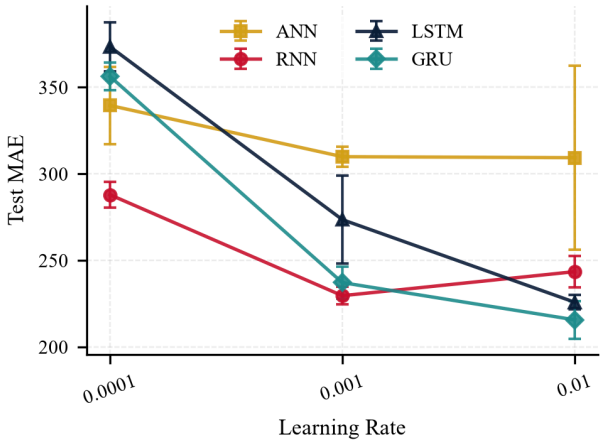


Fig. 6. Test MAE terhadap learning rate di Duomo (rata-rata ± SD, 3 seed).

Hasil komparasi laju pembelajaran menunjukkan dinamika optimasi sebagai berikut:

1) **Kegagalan Konvergensi pada Laju Terlalu Kecil ($\texttt{lr} = 10^{-4}$):** Pada nilai 10^{-4}, seluruh model (ANN, RNN, LSTM, GRU) menyentuh batas maksimum 300 epoch tanpa sekalipun memicu *early stopping* (rata-rata epoch tepat 300,0). Langkah pembaruan bobot yang terlampau lambat mengakibatkan model mengalami *severe underfitting* dan gagal mencapai lembah fungsi rugi dalam anggaran komputasi yang diberikan, sehingga val MAE melonjak sangat tinggi (LSTM $399,4 \pm 25,0$; GRU $398,4 \pm 8,6$; ANN $295,3$; RNN $285,0$).
2) **Keseimbangan Ideal pada Nilai Acuan ($\texttt{lr} = 10^{-3}$):** Nilai acuan 10^{-3} merupakan konfigurasi optimal bagi ANN ($248,9 \pm 8,9$), RNN ($206,1 \pm 7,4$), dan GRU ($207,5 \pm 3,8$). Pada nilai ini, mekanisme adaptif Adam berhasil memandu model menuju konvergensi stabil sebelum dihentikan oleh *early stopping* secara efisien pada rata-rata epoch 106–194.
3) **Kecepatan Konvergensi dan Keunggulan pada Model Bergerbang ($\texttt{lr} = 10^{-2}$):** Pada laju besar 10^{-2}, seluruh arsitektur berkonvergensi secara sangat kilat, di mana *early stopping* menghentikan pelatihan hanya dalam rata-rata 62–68 epoch. Menariknya, $\texttt{lr} = 10^{-2}$ menjadi konfigurasi terbaik bagi LSTM dengan penurunan val MAE signifikan ke level $\mathbf{215,9 \pm 14,2}$ (test MAE 225,8) serta mempertahankan performa prima pada GRU ($208,2 \pm 5,6$; test MAE 215,7). Ukuran langkah gradien yang lebih besar membantu mekanisme gerbang nonlinier sigmoid dan tanh keluar dengan cepat dari plateau jenuh pada awal inisialisasi bobot. Namun untuk Simple RNN tanpa gerbang, laju besar ini memicu sedikit instabilitas dan osilasi di sekitar kurva optimum sehingga val MAE sedikit terdegradasi ke $226,7 \pm 6,7$.

e) *A5. Pengaruh Kelompok Fitur Masukan:* Eksperimen A5 memvariasikan komposisi fitur masukan: net saja, net+call+sms, net+waktu, dan semua fitur. Hasil val MAE dirangkum pada Tabel VII, sedangkan test MAE divisualisasikan pada Fig. 7.

TABLE VII
PENGARUH KELOMPOK FITUR TERHADAP VAL MAE (RATA-RATA ± SD, 3 SEED). SEL TEBAL = NILAI TERBAIK PER MODEL.

Kelompok Fitur	ANN	RNN	LSTM	GRU
net	260,5 ± 7,0	245,2 ± 5,8	266,2 ± 5,7	264,6 ± 7,0
net+call+sms	259,9 ± 5,2	224,1 ± 2,3	243,7 ± 7,1	231,8 ± 12,6
net+waktu	**246,0 ± 9,8**	223,0 ± 9,5	231,1 ± 4,3	213,2 ± 18,2
semua	248,9 ± 8,9	**206,1 ± 7,4**	**230,5 ± 12,2**	**207,5 ± 3,8**

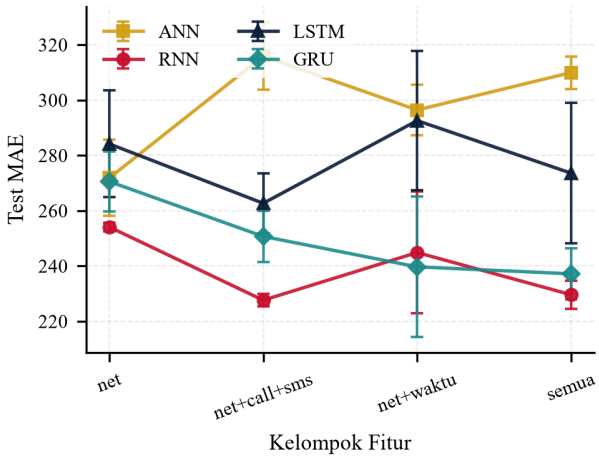


Fig. 7. Test MAE untuk empat kelompok fitur di Duomo (rata-rata ± SD, 3 seed).

Empat temuan utama dari variasi fitur:

1) **Target univariat tidak memadai.** Kelompok net saja memberi val MAE tertinggi untuk RNN (245,2), LSTM (266,2), dan GRU (264,6). Pada test, net saja

menghasilkan MAE RNN 254,1, LSTM 284,1, dan GRU 270,5, lebih tinggi daripada kombinasi yang menyertakan kanal lain.

2) **Kanal call dan sms konsisten membantu RNN dan LSTM.** Penambahan call+sms menurunkan val MAE RNN dari 245,2 menjadi 224,1 dan LSTM dari 266,2 menjadi 243,7. Pada test, penurunan yang setara terlihat dari 254,1 menjadi 227,6 (RNN) dan 284,1 menjadi 262,7 (LSTM).
3) **Fitur waktu memberi perbaikan val terbesar pada ANN dan GRU.** Kelompok net+waktu menurunkan val MAE ANN dari 260,5 menjadi 246,0 dan GRU dari 264,6 menjadi 213,2. Pada test, GRU membaik dari 270,5 menjadi 239,7, tetapi ANN justru memburuk dari 271,8 menjadi 296,4. Untuk ANN, nilai test terbaik diperoleh dengan net saja (271,8), sedangkan val terbaiknya dengan net+waktu, indikasi overfit pada fitur tambahan.
4) **Kombinasi semua fitur paling konsisten untuk model rekuren.** Kelompok semua fitur memberi val MAE terbaik untuk RNN (206,1), LSTM (230,5), dan GRU (207,5). Pada test, GRU tetap terbaik dengan semua fitur (237,2), sedangkan RNN dan LSTM sedikit lebih baik dengan net+call+sms (227,6 dan 262,7).

Secara keseluruhan tidak ada satu kelompok fitur yang unggul mutlak. Fitur waktu dan kanal call/sms sama-sama berguna, dan kombinasi semua fitur paling konsisten untuk model rekuren; ANN lebih sensitif terhadap penambahan fitur.

C. Bagian B — Ablasi Pilihan

Bagian ini menguji dua faktor tambahan yang dipilih sebelum eksperimen dijalankan, yaitu dropout (B2) dan horizon peramalan (B6). Keduanya diuji pada empat model dengan tiga random seed, sementara faktor lain dipertahankan pada konfigurasi acuan.

a) *B2. Dropout:*

Hipotesis. Dropout moderat ($p = 0,2$) meningkatkan generalisasi dibandingkan tanpa dropout ($p = 0$), sedangkan dropout agresif ($p = 0,5$) menyebabkan underfitting dan menaikkan error.

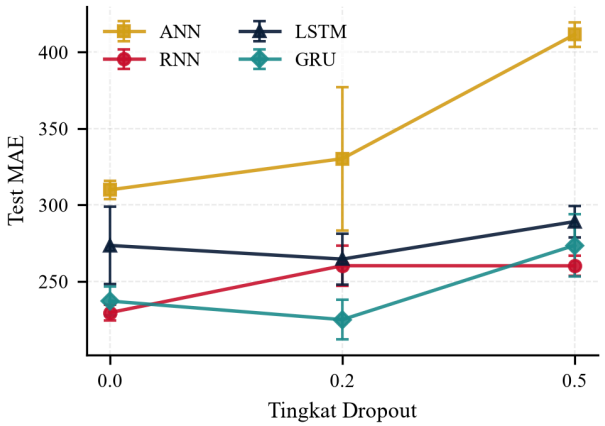


Fig. 8. Test MAE terhadap tingkat dropout pada empat model di Duomo (rata-rata ± SD, 3 seed).

Hasil. Dropout 0,2 menurunkan test MAE GRU dari 237,2 menjadi 225,0 (Natal 468,2 menjadi 429,7) dan LSTM dari 273,6 menjadi 264,6. Val MAE GRU juga membaik dari 207,5 menjadi 203,9. Sebaliknya, ANN memburuk dari 309,9 menjadi 330,3 dan RNN dari 229,6 menjadi 260,3. Dropout 0,5 menaikkan error seluruh model, dengan test MAE ANN 411,6, RNN 260,2, LSTM 289,1, dan GRU 273,6. Hasil lengkap terlihat pada Fig. 8.

Status hipotesis. Sebagian didukung. Manfaat dropout moderat hanya muncul pada model bergerbang, terutama GRU; klaim bahwa dropout selalu meningkatkan generalisasi tidak terbukti. Sebaliknya, underfitting pada $p = 0,5$ terbukti pada semua model.

b) *B6. Horizon Peramalan:*

Hipotesis. MAE meningkat monoton seiring bertambahnya horizon ($H = 1 < H = 6 < H = 24$). Pada $H = 1$, model neural network mengungguli baseline naif; pada $H = 24$, keunggulannya mengecil, dan model rekuren diprediksi lebih baik daripada ANN.

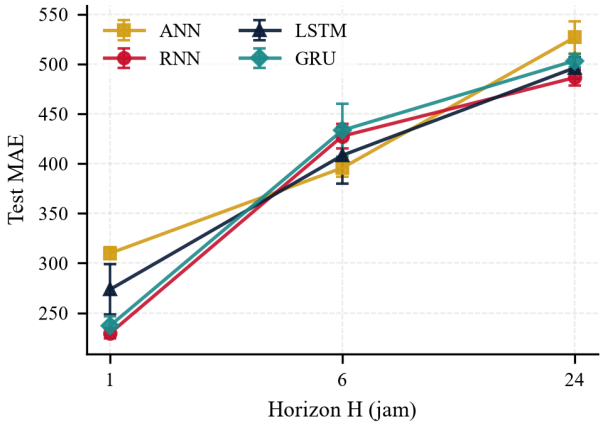


Fig. 9. Test MAE terhadap horizon peramalan pada empat model di Duomo (rata-rata ± SD, 3 seed).

Hasil. Test MAE meningkat monoton pada semua model. Pada $H = 1$, nilai berkisar 229,6–309,9 dan seluruh model mengungguli baseline naif terbaik (467,6). Pada $H = 6$, ANN 395,7, RNN 427,6, LSTM 408,3, dan GRU 433,4. Pada $H = 24$, ANN 526,8, RNN 486,4, LSTM 496,1, dan GRU 503,3; seluruh model justru kalah dari baseline naif minggu lalu (466,1). Pada horizon ini model rekuren mengungguli ANN, meskipun pada $H = 6$ ANN masih yang terbaik. MAE Natal pada $H = 24$ memburuk ke rentang 1.101,6–1.199,4. Tren lengkapnya ditunjukkan pada Fig. 9.

Status hipotesis. Didukung sepenuhnya untuk monotonisitas dan memburuknya keunggulan pada horizon panjang. Prediksi bahwa model rekuren mengungguli ANN juga terkonfirmasi pada $H = 24$, tetapi tidak pada $H = 6$.

D. Bagian C — Konfigurasi Terbaik

Berdasarkan hasil studi ablasi individual pada Bagian A dan B, konfigurasi terbaik untuk masing-masing arsitektur dipilih secara ketat hanya menggunakan metrik **validation MAE** terendah (Tabel VIII). Pemilihan berbasis validasi ini merefleksikan praktik perancangan model di dunia nyata

TABLE VIII

PERBANDINGAN PERFORMA KONFIGURASI ACUAN DAN TERBAIK DI DUOMO ($H = 1$ JAM, RATA-RATA $\pm$ SD, 3 SEED). SEL TEBAL = NILAI TEST TERBAIK PER MODEL.

Model	Konfigurasi	Param	Val MAE	Test MAE	Test MAPE	Natal MAE
ANN	Acuan	6.497	248,9 $\pm$ 8,9	309,9 $\pm$ 5,9	11,3 $\pm$ 0,8%	680,1 $\pm$ 52,0
ANN	**Terbaik**	4.097	230,1 $\pm$ 14,8	**288,1 $\pm$ 15,6**	9,6 $\pm$ 0,6%	617,7 $\pm$ 36,0
RNN	Acuan	5.305	206,1 $\pm$ 7,4	229,6 $\pm$ 5,1	8,5 $\pm$ 0,3%	421,2 $\pm$ 2,4
RNN	**Terbaik**	5.305	200,1 $\pm$ 5,3	**224,5 $\pm$ 11,7**	8,2 $\pm$ 0,8%	404,5 $\pm$ 9,9
LSTM	Acuan	5.578	230,5 $\pm$ 12,2	273,6 $\pm$ 25,4	9,1 $\pm$ 1,0%	586,0 $\pm$ 56,8
LSTM	**Terbaik**	70.273	221,3 $\pm$ 6,9	**225,3 $\pm$ 4,0**	7,3 $\pm$ 0,7%	454,5 $\pm$ 36,4
GRU	Acuan	5.397	207,5 $\pm$ 3,8	**237,2 $\pm$ 9,3**	8,0 $\pm$ 0,7%	**468,2 $\pm$ 21,8**
GRU	Terbaik	151.809	203,6 $\pm$ 7,3	239,7 $\pm$ 9,9	7,9 $\pm$ 0,4%	497,6 $\pm$ 16,8

untuk menghindari kebocoran data uji (**test leakage**). Horizon peramalan tetap dipertahankan $H = 1$ jam agar evaluasi tetap setara secara langsung dengan konfigurasi acuan standar.

Parameter terbaik yang digabungkan per model meliputi:

- **ANN Terbaik:** Jendela pendek $W = 6$ jam, 1 lapisan tersembunyi dengan kapasitas besar (128 unit), dan kelompok fitur `net+waktu`. Kombinasi ini memangkas jumlah parameter menjadi 4.097 (turun 36,9% dari acuan 6.497) sekaligus mengeliminasi derau fluktuasi panggilan/SMS pada matriks masukan yang diratakan.
- **RNN Terbaik:** Jendela observasi diperpanjang menjadi $W = 48$ jam (2 siklus sirkadian 24 jam penuh), mempertahankan kapasitas acuan (hidden 68 unit, 1 lapisan, 5.305 parameter), dengan seluruh 7 fitur multimodal.
- **LSTM Terbaik:** Jendela lokal pendek $W = 6$ jam, kapasitas memori besar (hidden 128 unit), 1 lapisan, dan *learning rate* lebih agresif $\texttt{lr} = 10^{-2}$ untuk mempercepat pelolosan dari plateau gerbang non-linear. Jumlah parameter meningkat menjadi 70.273.
- **GRU Terbaik:** Jendela $W = 48$ jam, 2 lapisan bertumpuk dengan kapasitas 128 unit, serta regulasi dropout moderat $p = 0,2$ pada seluruh 7 fitur masukan, dengan total 151.809 parameter.

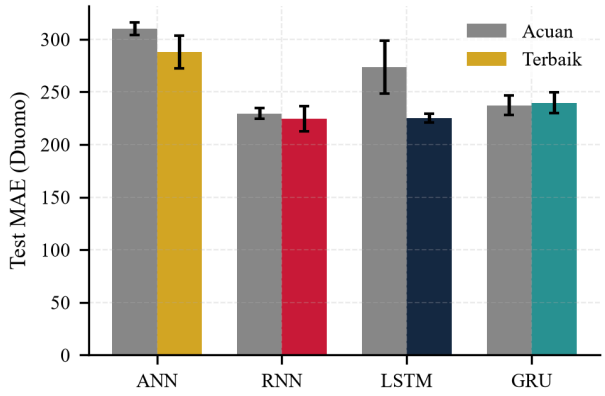


Fig. 10. Perbandingan Test MAE antara konfigurasi acuan dan terbaik di Duomo (rata-rata $\pm$ SD, 3 seed).

Hasil evaluasi pada Tabel VIII dan Fig. 10 menunjukkan beberapa dinamika penting:

1) **Peningkatan Signifikan pada Mayoritas Model:** Penyetelan gabungan sukses meningkatkan performa generalisasi pada 3 dari 4 arsitektur. Test MAE ANN terpangkas 21,8 poin menjadi 288,1 $\pm$ 15,6 (turun 7,0%), RNN turun menjadi 224,5 $\pm$ 11,7 (turun 2,2%), dan lonjakan paling dramatis dicapai oleh LSTM yang memangkas galat sebesar 48,3 poin dari 273,6 menjadi 225,3 $\pm$ 4,0 (turun 17,7%). LSTM terbaik juga mencatatkan simpangan baku antar-seed paling konsisten ($\pm 4,0$) serta MAPE paling presisi di antara seluruh model (**7,3 $\pm$ 0,7%**).
2) **Dominasi Terhadap Baseline Naif:** Seluruh konfigurasi acuan maupun terbaik mengungguli baseline naif terbaik minggu lalu (467,6) dengan margin error lebih dari 50% pada minggu uji reguler.
3) **Ketahanan Anomali Periode Natal:** Simple RNN terbaik memperlihatkan daya adaptasi tertinggi terhadap pergeseran distribusi libur akhir tahun, mencatatkan Natal MAE terendah sebesar **404,5 $\pm$ 9,9**, mengungguli seluruh baseline naif (naif nilai terakhir 431,2; naif kemarin 921,5; naif minggu lalu 1.426,2).
4) **Kasus Overfitting GRU Kapasitas Ekstrem:** Berbeda dari model lainnya, konfigurasi terbaik GRU justru mengalami degradasi tipis pada data uji reguler (test MAE 239,7 vs acuan 237,2) dan periode Natal (497,6 vs acuan 468,2), kendati val MAE-nya berhasil membaik (203,6 vs 207,5). Pertumbuhan parameter yang melonjak 28 kali lipat (151.809 vs 5.397) akibat penumpukan 2 lapisan rekuren 128 unit memicu penghafalan pola lokal pada set validasi yang tidak tergeneralisasi sempurna ke distribusi data uji masa depan.

E. Bagian D — Uji Generalisasi

Pengujian generalisasi spasial dilakukan dengan mengevaluasi langsung konfigurasi acuan dan konfigurasi terbaik pada lokasi kelompok, yaitu Navigli (Darsena), kotak 4555 dengan kode lokasi 1 (Tabel IX). Perbandingan test MAE kedua konfigurasi dirangkum pada Fig. 11, sedangkan karakteristik pola aktivitasnya ditunjukkan pada Fig. 12.

TABLE IX
EVALUASI GENERALISASI DI NAVIGLI, KOTAK 4555 ($H = 1$ JAM, RATA-RATA $\pm$ SD, 3 SEED)

Model	Konfigurasi	Param	Val MAE	Test MAE	Test MAPE	Natal MAE
ANN	Acuan	6.497	166,6 $\pm$ 5,3	222,3 $\pm$ 27,4	8,9 $\pm$ 1,1%	664,5 $\pm$ 190,8
ANN	**Terbaik**	4.097	138,4 $\pm$ 1,7	**191,1 $\pm$ 1,9**	7,9 $\pm$ 0,1%	607,7 $\pm$ 56,1
RNN	Acuan	5.305	147,3 $\pm$ 4,9	**193,0 $\pm$ 9,7**	7,8 $\pm$ 0,3%	534,7 $\pm$ 148,9
RNN	Terbaik	5.305	148,7 $\pm$ 7,7	211,7 $\pm$ 24,3	8,7 $\pm$ 1,0%	649,2 $\pm$ 92,5
LSTM	Acuan	5.578	164,3 $\pm$ 9,3	247,3 $\pm$ 54,3	10,0 $\pm$ 2,7%	950,8 $\pm$ 110,9
LSTM	**Terbaik**	70.273	147,2 $\pm$ 4,2	**210,4 $\pm$ 7,7**	8,5 $\pm$ 0,5%	738,4 $\pm$ 41,9
GRU	Acuan	5.397	149,0 $\pm$ 6,0	**190,8 $\pm$ 6,8**	7,8 $\pm$ 0,2%	496,4 $\pm$ 50,9
GRU	Terbaik	151.809	132,5 $\pm$ 2,1	223,1 $\pm$ 17,0	9,6 $\pm$ 0,7%	753,7 $\pm$ 49,8

Wilayah Navigli memiliki karakteristik tata ruang yang sangat kontras dibandingkan kawasan pusat perkantoran Duomo.

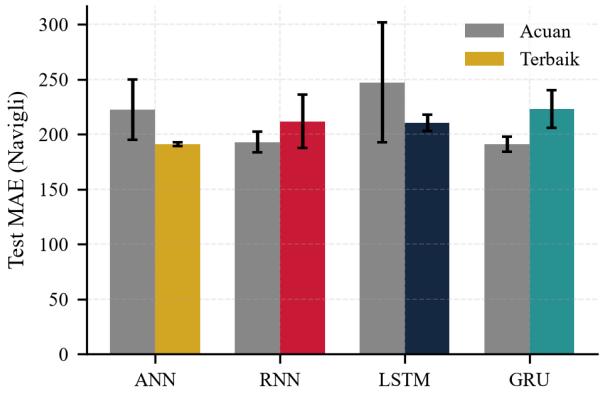


Fig. 11. Test MAE konfigurasi acuan dan terbaik di Navigli (rata-rata $\pm$ SD, 3 seed).

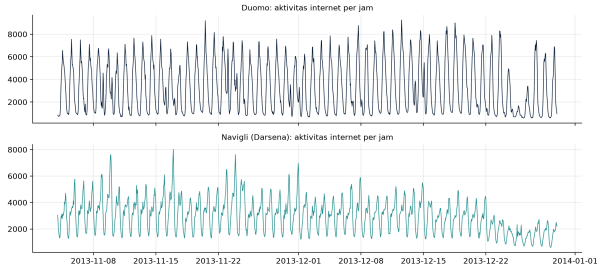


Fig. 12. Perbandingan pola aktivitas internet seluler per jam antara Duomo (kotak 5060) dan Navigli (kotak 4555).

a) *Pembalikan Peringkat Model (*Model Ranking Inversion*):*

Perbandingan lintas lokasi menyingkap fenomena struktural yang sangat fundamental:

1) **Urutan Model di Duomo (Pusat Bisnis):**
   - Model acuan: RNN $(229, 6)$ < GRU $(237, 2)$ < LSTM $(273, 6)$ < ANN $(309, 9)$.
   - Model terbaik: RNN $(224, 5)$ < LSTM $(225, 3)$ < GRU $(239, 7)$ < ANN $(288, 1)$.
   - Di kawasan perkantoran Duomo, seluruh varian rekuren mengungguli ANN secara mutlak, di mana ANN selalu menempati peringkat terbawah.
2) **Urutan Model di Navigli (Kawasan Hiburan Malam):**
   - Model acuan: GRU $(190, 8)$ < RNN $(193, 0)$ < ANN $(222, 3)$ < LSTM $(247, 3)$.
   - Model terbaik: $\mathbf{ANN\ (191, 1)}$ < $\mathbf{LSTM\ (210, 4)}$ < RNN $(211, 7)$ < GRU $(223, 1)$.
   - Terjadi pembalikan peringkat model secara total (**complete ranking reversal**). Model feedforward ANN yang berkinerja paling buruk di Duomo melesat menjadi **model nomor satu** paling akurat di Navigli dengan Test MAE 191,1 $\pm$ 1,9 dan simpangan baku paling stabil, melampaui seluruh arsitektur rekuren.

b) *Keterkaitan dengan Karakteristik Pola Trafik Spasial:*

Perubahan hierarki performa ini berhubungan erat dengan karakter fisis dan ritme sosial kawasan Navigli (Darsena):

1) **Karakter Aktivitas Malam dan Akhir Pekan:** Navigli merupakan pusat rekreasi kanal dan kehidupan malam (*nightlife*) yang dipenuhi kafe, bistro, bar, dan kelab malam. Sementara kurva beban Duomo didominasi oleh jam kerja teratur (Senin–Jumat, pukul 08.00–18.00) dengan puncak siang hari, kurva Navigli dicirikan oleh lonjakan impulsif pada malam hingga dini hari (pukul 20.00–03.00) serta akhir pekan (Jumat malam hingga Minggu) sebagaimana diilustrasikan pada Fig. 12.
2) **Efektivitas Konteks Pendek ($W = 6$) vs Distorsi Histori Panjang ($W = 48$):** Dinamika kerumunan hiburan malam bersifat sesaat, cepat berubah, dan didorong oleh mobilitas pengunjung situasional. Konfigurasi terbaik ANN dan LSTM sama-sama mengadopsi jendela pendek $W = 6$ jam. Jendela 6 jam hanya membaca eskalasi beban terdekat sesaat sebelum puncak malam dimulai (*recent trend*), sehingga sangat tanggap dan bebas dari residu memori dua hari sebelumnya. Sebaliknya, model dengan $W = 48$ jam (RNN dan GRU terbaik) membawa deretan memori 48 jam yang justru mengaburkan anomali impulsif akhir pekan dengan riwayat hari kerja pertengahan minggu yang relatif sepi, sehingga Test MAE keduanya terdegradasi di Navigli (RNN memburuk ke 211,7 dan GRU ke 223,1).
3) **Keunggulan Pemetaan Deterministik ANN:** Kombinasi 1 lapisan tersembunyi (128 unit) dengan fitur `net+waktu` memberikan sinyal penanda fase jam dan hari secara kontinu tanpa akumulasi ketergantungan sekuensial rekuren yang rentan terdistorsi oleh lonjakan tiba-tiba. ANN secara murni

memetakan pola lokal temporal dengan variansi paling sempit ($\pm 1, 9$).

4) **Perilaku Anomali Minggu Natal di Navigli:** Pada minggu perayaan Natal (23–29 Desember), denyut kehidupan malam kanal padam karena warga merayakan libur secara privat di kediaman masing-masing. Baseline naif nilai terakhir menjadi metode terkuat di Navigli (Natal MAE 177,7) karena trafik berada pada level rendah yang datar. Sebaliknya, model deep learning yang terbiasa mempelajari lonjakan akhir pekan reguler menghasilkan prediksi berlebih (**over-estimation**).

IV. Pembahasan

A. Mengapa Hasil Terjadi

Studi ini mengungkap bahwa keunggulan arsitektur deep learning dalam peramalan deret waktu seluler tidak bersifat universal, melainkan merupakan fungsi interaksi antara mekanisme memori model dan sifat stokastik dari dinamika temporal-spasial kawasan. Pada kawasan perkantoran teratur seperti Duomo, relasi temporal bersifat stasioner dan berulang secara berkala mengikuti ritme kerja mingguan, sehingga mekanisme propagasi hidden state langkah demi langkah pada RNN, LSTM, dan GRU sangat efisien dalam menyerap dependensi jangka panjang tanpa meledakkan dimensi bobot. Sebaliknya, pada wilayah dengan dinamika impulsif seperti Navigli, ketergantungan memori masa lalu yang terlampau panjang justru menjadi beban induktif (*inductive bias*) yang merugikan. Jaringan feedforward dengan jendela pendek dan fitur pengkodean waktu deterministik terbukti lebih adaptif terhadap pola lonjakan non-stasioner lokal.

B. Faktor Paling dan Paling Tidak Berpengaruh

Analisis sensitivitas dari rangkaian ablasi OFAT mengidentifikasi hierarki pengaruh hiperparameter sebagai berikut:

1) **Faktor Paling Berpengaruh:**
   - **Ukuran Hidden Unit (A2) dan Learning Rate (A4):** Keduanya menjadi penentu utama kestabilan optimasi. Ukuran hidden menggeser model secara drastis dari zona *underfitting* parah pada 16 unit (val MAE > 240) menuju saturasi representasi pada 64–128 unit. Sementara itu, *learning rate* 10^{-4} mengakibatkan kegagalan konvergensi total di seluruh model (stuck di 300 epoch tanpa pemicuan early stopping). Sebaliknya, laju besar 10^{-2} mempercepat konvergensi model bergerbang (LSTM dan GRU) hingga di bawah 70 epoch, namun memicu osilasi ketidakstabilan pada Simple RNN.
   - **Panjang Jendela W (A1):** Berpengaruh sangat kritis terhadap arsitektur feedforward. Perataan matriks $W \times 7$ pada ANN memicu penskalaan parameter linear yang melipatgandakan bobot dari 2.465 ($W = 6$) ke 38.753 ($W = 168$), menyebabkan overfitting parah. Sebaliknya, model rekuren memiliki parameter konstan terhadap W dan memperlihatkan ketahanan luar biasa terhadap variasi panjang konteks historis.
   - **Kedalaman Layer LSTM (A3):** Penambahan lapisan dari 1 ke 3 pada LSTM memicu degradasi katastropik (val MAE melonjak dari 230,5 ke 338,9) akibat resistensi gradien yang lenyap (*vanishing gradients*) saat melintasi tumpukan 3 pasang gerbang rekuren pada volume sampel latih moderat tanpa koneksi pintas (*residual connections*).

2) **Faktor Paling Tidak Berpengaruh:**
   - **Kedalaman Lapisan ANN (A3):** Penambahan lapisan dari 1, 2, hingga 3 lapis pada ANN menghasilkan rentang val MAE yang hampir identik ($240,9$ hingga $248,9$). Karena tugas peramalan berfokus pada pemetaan proyeksi univariat, kedalaman jaringan feedforward tidak memberikan abstraksi representasi hierarkis tambahan yang berarti.
   - **Penambahan Kanal Panggilan dan SMS pada ANN (A5):** Penggabungan multivariat `call` dan `sms` hanya menggeser val MAE ANN sebesar 0,6 poin (260,5 ke 259,9). Bagi feedforward ANN, derau fluktuasi panggilan/SMS tidak mampu disaring seefektif mekanisme gerbang pada model rekuren.

C. Variasi Antar-Seed vs Perbedaan Antar-Model

Perbandingan statistik menunjukkan bahwa signifikansi keunggulan arsitektural bergantung pada konteks evaluasi:

- Pada kondisi konfigurasi acuan di Duomo, margin perbedaan performa antar-arsitektur (misal selisih antara acuan RNN 229,6 dan acuan ANN 309,9 sebesar 80,3 poin) jauh lebih masif dibanding rentang deviasi standar stokastik inisialisasi bobot antar-seed ($\pm 5, 1$ hingga $\pm 25, 4$). Hal ini membuktikan bahwa dominasi keunggulan arsitektur rekuren atas ANN di kawasan bisnis berulang merupakan keunggulan struktural nyata, bukan kebetulan acak inisialisasi parameter.
- Namun, pada arsitektur yang berkapasitas sangat besar atau memiliki tumpukan lapisan yang dalam (seperti LSTM acuan $\pm 25, 4$, LSTM di Navigli $\pm 54, 3$, atau ANN di Navigli $\pm 27, 4$), variansi inisialisasi stokastik melebar secara signifikan. Kondisi ini menegaskan bahwa pelaporan hasil peramalan deret waktu berbasis deep learning mutlak membutuhkan protokol evaluasi multi-seed untuk menghindari kesimpulan prematur berbasis eksekusi tunggal.

D. Keterbatasan Studi

Studi ini memiliki sejumlah keterbatasan yang perlu dicatat untuk pengembangan ke depan:

1) **Cakupan Geografis dan Temporal Terbatas:** Eksperimen hanya mengevaluasi dua kotak seluler di Kota Milan dengan rentang waktu 56 hari (4 minggu data latih atau 672 observasi per jam). Karakteristik musiman tahunan tidak tercakup dalam dataset.

2) **Protokol Pemisahan Waktu Tunggal:** Evaluasi mengandalkan pembagian kronologis satu kali (**single chronological train/val/test split**), bukan skema validasi silang temporal bergulir (**rolling-origin / walk-forward evaluation**), sehingga rentan terhadap keunikan dinamika cuaca atau event lokal pada minggu uji tertentu.
3) **Ketiadaan Sampel Liburan Panjang pada Data Latih:** Data latih (November–awal Desember) sepenuhnya terdiri dari hari kerja dan akhir pekan reguler tanpa hari libur nasional. Akibatnya, seluruh model deep learning tidak memiliki memori pola libur panjang dan menderita pergeseran distribusi drastis pada minggu perayaan Natal.

V. Kesimpulan

Studi ablasi terkontrol ini membuktikan bahwa arsitektur rekuren (RNN, LSTM, dan GRU) secara konsisten mengungguli feedforward ANN dan baseline naif di kawasan bisnis Duomo, dengan test MAE acuan Simple RNN mencapai 229,6 $\pm$ 5,1 dibandingkan ANN 309,9 $\pm$ 5,9 dan baseline naif minggu lalu 467,6. Melalui penyesuaian hyperparameter berbasis val MAE, integrasi konfigurasi terbaik berhasil memangkas error LSTM menjadi 225,3 $\pm$ 4,0 (MAPE terbaik 7,3%) dan RNN menjadi 224,5 $\pm$ 11,7; namun model dengan kapasitas raksasa seperti GRU terbaik (151.809 parameter) mengalami overfitting yang sedikit mendegradasi performa uji menjadi 239,7 $\pm$ 9,9. Uji generalisasi di kawasan hiburan malam Navigli membalikkan urutan performa secara total, di mana model ANN terbaik dengan jendela pendek ($W = 6$) melesat menjadi model terbaik nomor satu (test MAE 191,1 $\pm$ 1,9), mengungguli seluruh varian rekuren. Temuan ini menegaskan bahwa keunggulan arsitektur deep learning sangat bergantung pada pola temporal spasial lokasi, serta pemilihan hyperparameter berbasis validasi memerlukan regularisasi yang memadai agar tidak terjebak dalam penghafalan pola lokal.

Kontribusi Anggota

Adif Dafa Raihan	Kerangka proyek dan README, eksperimen Bagian 0 dan A1, pelatihan Bagian C/D, tabel pemilihan faktor, Abstrak, Pendahuluan, Metode, analisis A5/B2/B6, verifikasi angka, dan integrasi laporan.
Cindy Auliya	Hipotesis dan evaluasi Bagian B, eksperimen A3, A4, B2, dan B6, serta analisis hasil Bagian 0 dan A1–A4.
Bima Cahya Ramadhan	Eksperimen A2 dan A5, evaluasi Bagian C/D, grafik dan tabel IEEE, serta penulisan Bagian C, Bagian D, Pembahasan, dan Kesimpulan.

Pernyataan Penggunaan AI

Alat AI yang kami gunakan adalah Antigravity CLI, Copilot CLI, OpenCode CLI, Gemini (model LLM), Copilot (model LLM), dan DeepSeek (model). Alat-alat tersebut digunakan untuk membantu penulisan kode eksperimen, analisis awal, dan penyuntingan bahasa laporan. Seluruh rancangan eksperimen, eksekusi pelatihan, dan angka yang dilaporkan berasal dari run kelompok sendiri yang tersimpan pada `hasil/ablasi.csv`; setiap keluaran AI kami periksa ulang terhadap data tersebut. AI tidak dipakai untuk menghasilkan atau mengubah angka hasil.

Referensi

[1] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.

[2] K. Cho *et al.*, "Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1724–1734. doi: 10.3115/v1/D14-1179.

[3] G. Barlacchi *et al.*, "A multi-source dataset of urban life in the city of Milan and the Province of Trentino," *Scientific Data*, vol. 2, p. 150055, 2015, doi: 10.1038/sdata.2015.55.

[4] C. Zhang, S. Dang, B. Shihada, and M.-S. Alouini, "Dual Attention-Based Federated Learning for Wireless Traffic Prediction," in *IEEE INFOCOM 2021 – IEEE Conference on Computer Communications*, 2021, pp. 1–10. doi: 10.1109/INFOCOM42981.2021.9488883.

[5] A. Paszke *et al.*, "PyTorch: An Imperative Style, High-Performance Deep Learning Library," in *Advances in Neural Information Processing Systems 32 (NeurIPS)*, 2019, pp. 8024–8035.