Studi Ablasi RNN, LSTM, dan GRU dibandingkan ANN untuk Prediksi Trafik Seluler Kota Milan

Adif Dafa Raihan
NIM 124400055
Teknik Telekomunikasi, ITERA
adif.124400055@student.itera.ac.id

Cindy Auliya
NIM 124400045
Teknik Telekomunikasi, ITERA
cindy.124400045@student.itera.ac.id

Bima Cahya Ramadhan
NIM 124400001
Teknik Telekomunikasi, ITERA
bima.124400001@student.itera.ac.id

***Abstract*—Pertumbuhan trafik internet seluler menuntut operator meramalkan beban setiap sel secara akurat agar kapasitas dan energi jaringan dialokasikan secara efisien. Penelitian ini membandingkan ANN dengan RNN, LSTM, dan GRU untuk prediksi trafik per jam pada dataset Telecom Italia Big Data Challenge di Milan, dengan lokasi utama Duomo (kotak 5060) dan uji generalisasi di Navigli (kotak 4555). Kami melakukan studi ablasi terkontrol dengan mengubah satu faktor setiap kali, yaitu panjang jendela, ukuran hidden, jumlah lapisan, learning rate, kelompok fitur, dropout, dan horizon, masing-masing dengan tiga random seed. Konfigurasi dipilih hanya berdasarkan val MAE, lalu diuji pada minggu test dan periode Natal. Pada konfigurasi acuan, RNN memberikan test MAE terbaik (229,6 ± 5,1) dan mengungguli baseline naif minggu lalu (467,6), sedangkan ANN terlemah di antara empat model (309,9 ± 5,9). Penyetelan menurunkan MAE RNN menjadi 224,5 dan LSTM dari 273,6 menjadi 225,3, tetapi konfigurasi terbaik GRU justru memburuk (239,7 versus 237,2) karena overfit. Di Navigli urutan berubah dan ANN menjadi terbaik (191,1 ± 1,9). Hasil ini menunjukkan bahwa keunggulan model sekuensial bergantung pada lokasi dan bahwa pemilihan hyperparameter berbasis validasi tidak selalu menjamin perbaikan pada data uji.**

***Index Terms*—prediksi trafik seluler, RNN, LSTM, GRU, studi ablasi**

I. Pendahuluan

Pertumbuhan trafik data seluler menuntut operator meramalkan permintaan tiap sel secara akurat untuk alokasi kapasitas, efisiensi energi, dan kualitas layanan. Peramalan yang terlalu rendah menyebabkan kongesti, sedangkan peramalan yang terlalu tinggi membuang kapasitas. Karena trafik mengikuti ritme harian, mingguan, dan karakter kawasan, model perlu menangkap dependensi temporal, bukan hanya hubungan antarfitur pada satu waktu.

ANN meratakan jendela observasi sehingga urutan waktu hilang. Recurrent neural network (RNN) mempertahankan hidden state, tetapi rentan terhadap vanishing gradient. Long short-term memory (LSTM) menambahkan gerbang input, forget, dan output serta cell state [1], sedangkan gated recurrent unit (GRU) menyederhanakannya menjadi gerbang reset dan update [2]. Keunggulan model sekuensial tidak otomatis karena bergantung pada panjang jendela, kapasitas hidden, kedalaman, learning rate, fitur, regularisasi, dan horizon. Studi ablasi yang mengubah satu faktor setiap kali memisahkan pengaruh faktor tersebut dari variasi antar-seed.

Kontribusi laporan ini ada tiga. Pertama, ablasi terkontrol lima faktor utama (panjang jendela, ukuran hidden, jumlah lapisan, learning rate, kelompok fitur) dan dua faktor tambahan (dropout, horizon) pada empat model dengan tiga seed di Duomo. Kedua, pemilihan konfigurasi hanya dari val MAE, lalu evaluasi pada minggu test dan Natal bersama baseline naif. Ketiga, uji generalisasi konfigurasi acuan dan terbaik di Navigli (kotak 4555, kode 1).

II. Data dan Metode

A. Dataset

Data berasal dari Telecom Italia Big Data Challenge [3] yang mencakup aktivitas jaringan di Kota Milan, Italia. Kami memakai versi agregasi per jam [4] untuk periode 4 November–29 Desember 2013, sehingga setiap lokasi memiliki 1.344 observasi atau 56 hari. Setiap catatan memuat tiga kanal trafik, yaitu internet (net), panggilan (call), dan SMS (sms). Fitur masukan berjumlah tujuh: net, call, sms, serta empat fitur waktu berupa sinus dan kosinus jam (jam_sin, jam_cos) dan hari (hari_sin, hari_cos). Fitur waktu merepresentasikan periodisitas sirkadian dan mingguan secara kontinu. Target peramalan adalah net satu jam ke depan.

Lokasi utama penelitian adalah kotak Duomo 5060 yang mewakili pusat aktivitas kota. Sebagai uji generalisasi, kami memakai lokasi kelompok, yaitu Navigli (Darsena) pada kotak 4555 dengan kode lokasi 1. Sebaran kedua lokasi ditunjukkan pada Fig. 1.

B. Pembagian Data dan Praproses

Pembagian data dilakukan secara kronologis: train 11 November–8 Desember 2013 (672 jam), validasi 9–15 Desember, test 16–22 Desember, dan periode Natal 23–29 Desember. Minggu pertama, 4–10 November, tidak dipakai sebagai sampel latih dan hanya menjadi konteks jendela bagi sampel awal. Pembagian ini memisahkan masa depan dari masa lalu sehingga tidak ada informasi test yang bocor ke pelatihan.

Standardisasi z-score dihitung dari rata-rata dan simpangan baku data sebelum 9 Desember, yaitu data latih beserta minggu konteks. Statistik tersebut kemudian diterapkan pada validasi, test, dan Natal. Dengan cara ini, model tidak pernah melihat statistik periode evaluasi. Jendela masukan dibentuk dengan panjang $W = 24$ jam dan horizon $H = 1$ jam, sehingga terdapat 672 jendela latih.

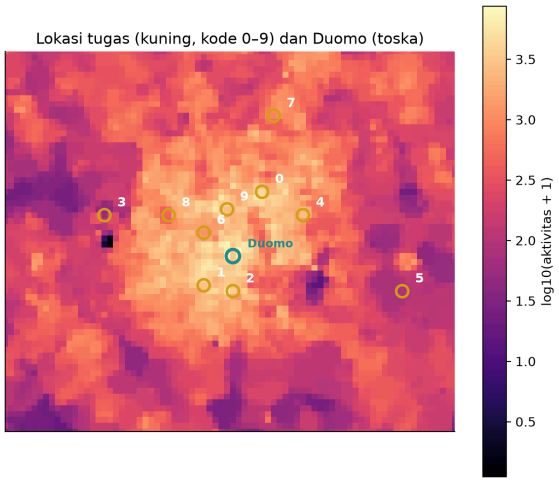


Fig. 1. Rata-rata aktivitas internet per kotak di Milan. Lingkaran kuning menunjukkan lokasi tugas (kode 0–9); lingkaran toska menunjukkan Duomo.

Sebuah jendela dimasukkan ke split tertentu berdasarkan waktu targetnya, bukan waktu awal jendela. Prediksi dikembalikan ke skala asli sebelum metrik dihitung.

Data deret waktu tidak diacak pada tahap pembagian karena pengacakan akan mencampur masa lalu dan masa depan serta merusak urutan yang menjadi objek peramalan. Pengacakan hanya dilakukan pada urutan mini-batch selama pelatihan; setiap jendela tetap mempertahankan urutan internalnya.

C. Model dan Konfigurasi Acuan

ANN meratakan jendela $W \times 7$ menjadi vektor dan memetakannya melalui dua lapisan tersembunyi berukuran 32 dengan aktivasi ReLU. Model ini tidak memodelkan urutan secara eksplisit. RNN sederhana memproses jendela langkah demi langkah dengan hidden state berukuran 68 dan memakai state terakhir untuk prediksi. LSTM memakai hidden state 33 serta tiga gerbang dan cell state [1], sedangkan GRU memakai hidden state 38 dengan dua gerbang [2]. Pada ketiga model rekuren, keluaran diambil dari hidden state langkah terakhir, lalu dilewatkan satu lapisan linear.

Semua model dilatih dengan fungsi loss MSE dan optimizer Adam (learning rate 10^{-3}), batch 64, serta early stopping pada val MSE dengan patience 30 dan maksimum 300 epoch. Bobot terbaik dipilih dari epoch dengan val MSE terendah. Pelatihan diimplementasikan dengan PyTorch [5]. Konfigurasi acuan dirangkum pada Tabel I.

D. Protokol Ablasi dan Evaluasi

Setiap eksperimen mengubah satu faktor dari konfigurasi acuan, sedangkan faktor lain dipertahankan. Faktor A1 menguji panjang jendela $W \in \{6, 12, 24, 48, 168\}$ jam; A2 ukuran hidden $\{16, 32, 64, 128\}$; A3 jumlah lapisan $\{1, 2, 3\}$; A4 learning rate $\{10^{-4}, 10^{-3}, 10^{-2}\}$; dan A5 kelompok fitur {net, net+call+sms, net+waktu, semua}. Dua faktor tambahan adalah B2 dropout {0; 0,2; 0,5} dan B6 horizon {1, 6, 24} jam.

TABLE I
KONFIGURASI ACUAN DAN JUMLAH PARAMETER

Hyperparameter	**Nilai acuan**
Panjang jendela W	24 jam
Horizon	1 jam
Ukuran hidden	ANN 32, RNN 68, LSTM 33, GRU 38
Jumlah lapisan	ANN 2, rekuren 1
Fitur	net, call, sms, jam (sin/cos), hari (sin/cos) — 7 fitur
Jumlah parameter	ANN 6.497, RNN 5.305, LSTM 5.578, GRU 5.397
Optimizer, *learning rate*	Adam, 10^{-3}
Batch size	64
Early stopping	*patience* 30, maks. 300 epoch

Setiap konfigurasi dilatih dengan tiga random seed, yaitu 0, 1, dan 2, lalu dilaporkan sebagai rata-rata $\pm$ simpangan baku.

Evaluasi memakai MAE, RMSE, dan MAPE pada skala asli. MAE menjadi metrik utama karena satuannya sama dengan aktivitas trafik, sedangkan MAPE memberi gambaran error relatif. Pemilihan konfigurasi terbaik hanya memakai val MAE; data test dan Natal tidak dipakai sampai evaluasi akhir. Konfigurasi terbaik tiap model kemudian digabungkan pada Bagian C dan diuji generalisasinya pada Bagian D.

Seluruh pelatihan dijalankan pada CPU dengan PyTorch. Sebanyak 270 pelatihan unik (348 catatan run karena beberapa konfigurasi acuan dipakai ulang) memerlukan total waktu 92,6 menit.

III. HASIL

A. Bagian 0 — Baseline Naif dan Model Acuan

Evaluasi diawali dengan membandingkan performa model deep learning pada konfigurasi acuan terhadap tiga metode baseline naif tanpa parameter di lokasi Duomo (kotak 5060) dengan horizon peramalan satu jam ($H = 1$). Tiga baseline naif yang diuji mencakup:

1) **Naif nilai terakhir** (*persistence*, $\hat{y}_t = y_{t-1}$), yang mengasumsikan trafik satu jam ke depan identik dengan nilai satu jam sebelumnya;
2) **Naif kemarin** ($\hat{y}_t = y_{t-24}$), yang memanfaatkan siklus harian (sirkadian 24 jam); serta
3) **Naif minggu lalu** ($\hat{y}_t = y_{t-168}$), yang memproyeksikan aktivitas trafik pada jam yang sama di hari yang sama pada minggu sebelumnya.

Hasil komparasi kinerja baseline naif dan empat arsitektur deep learning acuan (ANN, RNN, LSTM, GRU) disajikan pada Tabel II. Seluruh nilai model acuan dilaporkan sebagai rata-rata $\pm$ simpangan baku dari tiga *random seed* (0, 1, 2).

a) *Performa pada Kondisi Reguler (Minggu Test):*

Pada periode evaluasi normal (minggu test 16–22 Desember 2013), metode baseline naif menunjukkan bahwa trafik seluler memiliki ketergantungan musiman yang kuat. Baseline naif minggu lalu menjadi metode nirparameter terkuat dengan test MAE 467,6, mengungguli naif kemarin

TABLE II
BASELINE NAIF DAN KONFIGURASI ACUAN DI DUOMO ($H = 1$ JAM, RATA-RATA $\pm$ SIMPANGAN BAKU, 3 SEED)

Metode / Model	Param	Val MAE	Test MAE	Test MAPE	Natal MAE
Naif: nilai terakhir	0	662,6	600,9	18,4%	431,2
Naif: kemarin	0	595,3	552,2	23,8%	921,5
Naif: minggu lalu	0	492,8	467,6	19,9%	1.426,2
ANN (Acuan)	6.497	248,9 $\pm$ 8,9	309,9 $\pm$ 5,9	11,3 $\pm$ 0,8%	680,1 $\pm$ 52,0
RNN (Acuan)	5.305	206,1 $\pm$ 7,4	229,6 $\pm$ 5,1	8,5 $\pm$ 0,3%	421,2 $\pm$ 2,4
LSTM (Acuan)	5.578	230,5 $\pm$ 12,2	273,6 $\pm$ 25,4	9,1 $\pm$ 1,0%	586,0 $\pm$ 56,8
GRU (Acuan)	5.397	207,5 $\pm$ 3,8	237,2 $\pm$ 9,3	8,0 $\pm$ 0,7%	468,2 $\pm$ 21,8

(552,2) dan naif nilai terakhir (600,9). Hal ini mengonfirmasi bahwa pola hari kerja versus akhir pekan berulang secara reguler pada skala mingguan di pusat perkantoran Duomo.

Kendati demikian, seluruh model deep learning mampu mengungguli baseline naif terbaik secara signifikan. Model ANN acuan menurunkan test MAE menjadi 309,9 $\pm$ 5,9 (turun 33,7% dari naif minggu lalu). Ketiga arsitektur rekuren menunjukkan keunggulan yang lebih tajam: LSTM mencapai test MAE 273,6 $\pm$ 25,4 (turun 41,5%), GRU mencapai 237,2 $\pm$ 9,3 (turun 49,3%), dan Simple RNN mencatatkan kesalahan terendah sebesar 229,6 $\pm$ 5,1 (turun 50,9%). Keunggulan telak model rekuren dibanding ANN membuktikan bahwa mekanisme memori sekuensial langkah demi langkah jauh lebih efektif menangkap lintasan temporal dibanding sekadar meratakan matriks jendela observasi $W \times 7$ menjadi satu vektor input pada feedforward ANN.

b) *Analisis MAPE (*Mean Absolute Percentage Error*):*

Metrik MAPE memberikan gambaran kesalahan relatif terhadap fluktuasi magnitudo trafik asli. Pada metode naif, MAPE berkisar antara 18,4% (nilai terakhir) hingga 23,8% (kemarin). Naif kemarin mengalami persentase kesalahan tertinggi karena pergeseran fasa jam antarhari sering memicu error relatif besar pada jam-jam sepi (dini hari).

Sebaliknya, seluruh model deep learning memangkas batas MAPE ke kisaran 8,0%–11,3%. GRU menghasilkan test MAPE paling presisi yaitu **8,0 $\pm$ 0,7%**, diikuti oleh RNN (8,5 $\pm$ 0,3%), LSTM (9,1 $\pm$ 1,0%), dan ANN (11,3 $\pm$ 0,8%). Keunggulan GRU pada metrik persentase mengindikasikan bahwa struktur gerbang *reset* dan *update* miliknya sangat adaptif dalam menjaga proporsi simpangan yang stabil di seluruh kontur kurva beban, baik pada saat trafik mencapai lembah di malam hari maupun puncak pada jam sibuk siang hari.

c) *Perilaku pada Anomali Minggu Natal:*

Minggu Natal (23–29 Desember 2013) menjadi pengujian ekstrem atas ketahanan model terhadap pergeseran distribusi temporal (*distribution drift*). Karena kawasan Duomo merupakan pusat perkantoran, perbankan, dan komersial, perayaan malam dan hari Natal (24–26 Desember) memicu penurunan aktivitas kerja yang sangat tajam dibanding hari kerja normal.

Perubahan pola struktural ini menyebabkan baseline naif berbasis kalender mengalami kehancuran katastropik:

1) **Naif minggu lalu** runtuh total dengan lonjakan MAE lebih dari 200% menjadi **1.426,2** (MAPE melonjak mendekati 97%). Metode ini salah memproyeksikan beban kerja padat dari minggu sebelumnya ke hari libur perayaan Natal.
2) **Naif kemarin** turut mengalami degradasi parah hingga MAE **921,5** (MAPE 42,2%) saat transisi hari normal ke hari libur berlangsung.
3) Sebaliknya, **naif nilai terakhir** justru membaik menjadi MAE **431,2** (lebih rendah dibanding performa test regulernya 600,9). Ketika aktivitas masyarakat surut dan pola trafik bertahan pada level rendah yang datar, persistensi sesaat $(t-1)$ tidak terjebak oleh asumsi musiman mingguan yang keliru.

Bagi model deep learning, tidak adanya sampel hari libur dalam data latih (11 November–8 Desember) menyebabkan seluruh model mengalami kenaikan error. Namun, arsitektur rekuren memperlihatkan daya tahan yang jauh lebih tinggi daripada ANN:

- **Simple RNN (Acuan)** menjadi model paling tangguh dengan Natal MAE terendah sebesar **421,2 $\pm$ 2,4** (bahkan mengungguli seluruh baseline naif, termasuk naif nilai terakhir 431,2, serta memiliki variansi antar-seed terkecil $\pm 2,4$).
- **GRU (Acuan)** menyusul di peringkat kedua dengan Natal MAE **468,2 $\pm$ 21,8**.
- Sebaliknya, **LSTM** (586,0 $\pm$ 56,8) dan **ANN** (680,1 $\pm$ 52,0) menderita degradasi drastis. Tingginya lonjakan error pada ANN disebabkan oleh ketergantungannya pada bobot statis fitur kalender (hari dalam seminggu) yang memaksakan keluaran trafik tinggi pada hari Selasa–Kamis kalender, padahal realitas aktivitas perkantoran Duomo sedang tutup total untuk libur akhir tahun.

B. Bagian A — Ablasi Wajib

Pada bagian ini, dilakukan studi ablasi terkontrol menggunakan protokol *one-factor-at-a-time* (OFAT). Setiap subbagian (A1 hingga A5) hanya memvariasikan tepat satu faktor hiperparameter secara terisolasi, sementara seluruh faktor lainnya dibekukan pada nilai konfigurasi acuan (Tabel I), yaitu $W = 24$ jam, horizon $H = 1$ jam, ukuran hidden acuan (ANN 32, RNN 68, LSTM 33, GRU 38), kedalaman acuan (ANN 2 lapis, rekuren 1 lapis), kelompok fitur lengkap (7 fitur), optimizer Adam dengan *learning rate* 10^{-3}, dan *batch size* 64. Setiap eksperimen dijalankan secara independen pada tiga *random seed* (0, 1, 2) untuk memisahkan dampak arsitektural dari variasi stokastik inisialisasi bobot dan pengacakan batch. Pemilihan konfigurasi terbaik didasarkan murni pada metrik *validation* MAE guna menghindari kebocoran informasi uji (*test data leakage*).

a) *A1. Pengaruh Panjang Jendela Observasi (W):*

Eksperimen A1 menguji pengaruh panjang konteks historis masukan dengan memvariasikan $W \in \{6, 12, 24, 48, 168\}$ jam (mencakup rentang dari seperempat hari hingga satu minggu penuh). Hasil pengukuran *validation* MAE disajikan pada Tabel III, dan tren perbandingannya diilustrasikan pada Fig. 2.

TABLE III
PENGARUH PANJANG JENDELA W (JAM) TERHADAP VAL MAE (RATA-RATA ± SD, 3 SEED)

W (jam)	ANN	RNN	LSTM	GRU
6	**211,5 ± 6,2**	215,5 ± 4,1	**227,1 ± 4,3**	212,6 ± 11,5
12	238,5 ± 4,5	206,7 ± 6,2	235,6 ± 2,0	208,9 ± 10,4
24	248,9 ± 8,9	206,1 ± 7,4	230,5 ± 12,2	207,5 ± 3,8
48	262,6 ± 3,8	**200,1 ± 5,3**	249,1 ± 21,8	**206,7 ± 5,0**
168	298,2 ± 18,2	204,8 ± 10,2	241,4 ± 8,1	206,7 ± 5,1

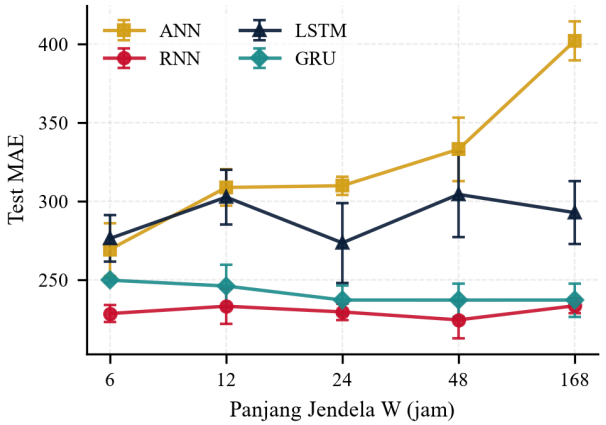


Fig. 2. Pengaruh panjang jendela W terhadap performa model di Duomo.

Dari hasil eksperimen terungkap dua pola perilaku yang sangat kontras:

1) **Degradasi Monotonik pada Feedforward ANN:** ANN memperlihatkan sensitivitas negatif yang tajam terhadap bertambahnya panjang jendela. Val MAE terendah ANN diraih pada $W = 6$ jam ($211,5 \pm 6,2$; test MAE 269,4), lalu membengkak seiring kenaikan W hingga puncaknya pada $W = 168$ jam ($298,2 \pm 18,2$; test MAE 402,0). Karena ANN meratakan matriks jendela observasi, penambahan panjang jendela melipatgandakan jumlah parameter secara drastis (dari 2.465 parameter pada $W = 6$ melonjak ke 38.753 parameter pada $W = 168$ dengan input layer berdimensi $168 \times 7 = 1.176$). Akibatnya, pada sampel data latih yang terbatas (672 sampel), ANN terjerumus ke dalam fenomena *curse of dimensionality* dan *overfitting* yang parah.
2) **Ketahanan Jangka Panjang pada Model Rekuren:** Sebaliknya, model rekuren memiliki parameter yang konstan terhadap dimensi waktu ($O(1)$ terhadap W, yakni RNN tetap 5.305 dan GRU 5.397 parameter). Simple RNN dan GRU mencapai titik optimum pada jendela multi-hari $W = 48$ jam (2 hari penuh), dengan val MAE masing-masing sebesar $\mathbf{200,1 \pm 5,3}$ (test MAE 224,5) dan $\mathbf{206,7 \pm 5,0}$ (test MAE 237,1). Pada jendela satu minggu penuh ($W = 168$), performa RNN ($204,8 \pm 10,2$) dan GRU ($206,7 \pm 5,1$) tetap sangat stabil dan tidak mengalami lonjakan error seperti ANN. Hal ini membuktikan keunggulan intrinsik mekanisme pemrosesan sekuensial rekuren dalam memfilter sinyal deret waktu panjang tanpa membebani kompleksitas bobot.
3) **Perilaku LSTM:** LSTM mencapai val MAE optimal pada jendela pendek $W = 6$ jam ($227,1 \pm 4,3$). Pada jendela yang lebih panjang ($W = 48$), variansi hasil LSTM meningkat cukup lebar ($\pm 21,8$) akibat kesulitan algoritma optimasi dalam menyeimbangkan gradien tiga pasang gerbang pada sekuens panjang tanpa koneksi residual.

b) *A2. Pengaruh Ukuran Lapisan Tersembunyi (*Hidden Units*):*

Eksperimen A2 mengevaluasi kapasitas representasi dengan memvariasikan dimensi hidden state $\in \{16, 32, 64, 128\}$. Hasil val MAE dirangkum pada Tabel IV, sedangkan visualisasi dinamika performa dan dampaknya terhadap jumlah parameter disajikan pada Fig. 3 dan Fig. 4.

TABLE IV
PENGARUH UKURAN HIDDEN TERHADAP VAL MAE (RATA-RATA ± SD, 3 SEED)

Ukuran Hidden	ANN	RNN	LSTM	GRU
16	257,6 ± 28,0	247,0 ± 5,8	244,3 ± 18,3	216,8 ± 21,2
32	248,9 ± 8,9	218,7 ± 6,6	241,5 ± 20,5	210,2 ± 0,8
64	238,4 ± 16,5	**207,2 ± 12,8**	218,1 ± 1,9	198,4 ± 9,2
128	**233,8 ± 1,9**	207,7 ± 7,2	**207,1 ± 8,4**	**188,7 ± 4,2**

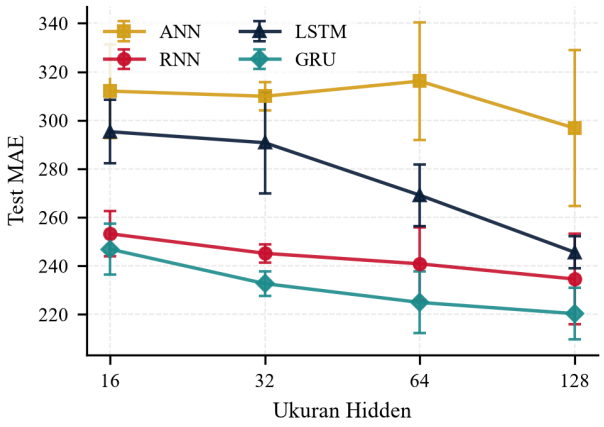


Fig. 3. Pengaruh variasi ukuran hidden terhadap val MAE.

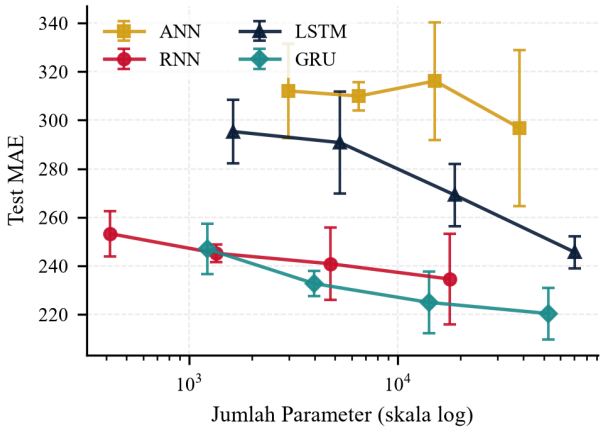


Fig. 4. Pertumbuhan parameter model terhadap ukuran hidden.

Dampak kapasitas terhadap performa dan kompleksitas komputasi model dapat dianalisis sebagai berikut:

1) **Underfitting pada Kapasitas Rendah:** Ukuran hidden 16 menghasilkan kesalahan tertinggi pada seluruh model (val MAE ANN 257,6; RNN 247,0; LSTM 244,3; GRU 216,8). Kapasitas memori 16 unit terbukti terlalu sempit untuk mengekstraksi dinamika multivariat gabungan dari 7 fitur masukan.
2) **Penskalaan Kuadratik Parameter:** Jumlah parameter sel rekuren bertumbuh secara kuadratik terhadap ukuran hidden ($O(h^2)$). Pada hidden 128, parameter LSTM melonjak drastis hingga 70.273 parameter, GRU mencapai 52.737 parameter, ANN 38.273 parameter, dan Simple RNN 17.665 parameter.
3) **Keuntungan Kapasitas Besar dan Titik Jenuh:** Peningkatan hidden hingga 128 secara konsisten menurunkan val MAE pada semua arsitektur. GRU 128 mencetak skor validasi terendah di seluruh studi ablasi ($\mathbf{188,7 \pm 4,2}$; test MAE 220,3), diikuti LSTM 128 ($\mathbf{207,1 \pm 8,4}$; test MAE 245,6), dan ANN 128 ($\mathbf{233,8 \pm 1,9}$). Pada RNN, ukuran 64 unit ($207,2 \pm 12,8$) sudah mencapai titik jenuh, di mana pelipatgandaan ke 128 unit tidak memberikan penurunan error yang signifikan ($207,7 \pm 7,2$). Kendati kapasitas 128 unit memberi representasi non-linear yang sangat ekspresif, pembengkakan parameter ini meningkatkan risiko overfitting jika tanpa regularisasi.

c) *A3. Pengaruh Kedalaman Lapisan (*Number of Layers*):*
Eksperimen A3 menguji kedalaman hierarki representasi dengan memvariasikan jumlah lapisan tersembunyi $\in \{1, 2, 3\}$. Hasil pengukuran disajikan pada Tabel V dan Fig. 5.

TABLE V
PENGARUH JUMLAH LAPISAN TERHADAP VAL MAE (RATA-RATA ± SD, 3 SEED)

Jumlah Lapisan	ANN	RNN	LSTM	GRU
1	**240,9 ± 7,5**	**206,1 ± 7,4**	**230,5 ± 12,2**	207,5 ± 3,8
2	248,9 ± 8,9	207,3 ± 9,1	254,8 ± 14,5	**203,3 ± 9,6**
3	244,9 ± 5,4	225,1 ± 12,7	338,9 ± 16,9	212,2 ± 15,9

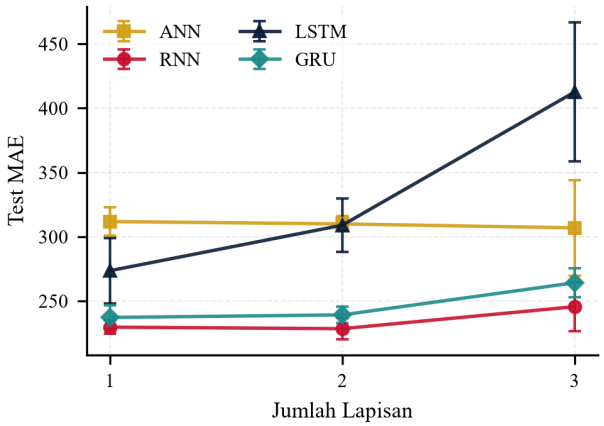


Fig. 5. Pengaruh variasi jumlah lapisan terhadap performa model.

Temuan krusial dari variasi kedalaman meliputi:

1) **Stabilitas Arsitektur Dangkal pada Feedforward ANN:** Penambahan lapisan ANN dari 1 ke 2 dan 3 lapis menghasilkan rentang val MAE yang hampir identik (240, 9 hingga 248, 9). Karena deret waktu ini berpusat pada target univariat tunggal, penumpukan lapisan feedforward tidak memberikan abstraksi hierarkis tambahan yang bermakna.
2) **Optimum Dangkal pada RNN dan GRU:** Simple RNN mencapai performa terbaik pada 1 lapisan rekuren ($206,1 \pm 7,4$), dan mulai mengalami peningkatan galat pada 3 lapisan ($225,1 \pm 12,7$). GRU meraih hasil terbaik pada 2 lapisan ($203,3 \pm 9,6$), sebelum terdegradasi pada 3 lapisan ($212,2 \pm 15,9$).
3) **Kasus Ekstrem Kegagalan LSTM Tiga Lapis:** Fenomena paling mencolok terjadi pada arsitektur LSTM, di mana penambahan kedalaman menjadi 3 lapisan memicu degradasi performa yang katastropik. Val MAE LSTM melonjak drastis dari $\mathbf{230,5 \pm 12,2}$ (1 lapis) menjadi $\mathbf{338,9 \pm 16,9}$ (3 lapis), sementara Test MAE anjlok ke level **412,6**. Fenomena ini disebabkan oleh hambatan propagasi balik gradien (*vanishing gradients*) yang berlipat ganda saat melintasi tiga tumpukan gerbang rekuren tanpa jalur koneksi *skip-connection* / residual. Dikombinasikan dengan ukuran dataset latih yang terbatas (672 jam), model 3-lapis LSTM terjebak dalam minimum lokal yang buruk. Hal ini membuktikan bahwa untuk peramalan trafik seluler berskala data moderat, model rekuren berarsitektur dangkal (1–2 lapis) jauh lebih

unggul dan mudah dilatih dibanding jaringan dalam (*deep recurrent networks*).

d) *A4. Pengaruh Laju Pembelajaran (*Learning Rate*):* Eksperimen A4 menguji stabilitas dan kecepatan konvergensi terhadap learning rate optimizer Adam dengan variasi $\text{lr} \in \{10^{-4}, 10^{-3}, 10^{-2}\}$. Hasil val MAE dirangkum pada Tabel VI, dan dinamika performa divisualisasikan pada Fig. 6.

TABLE VI
PENGARUH LEARNING RATE TERHADAP VAL MAE (RATA-RATA ± SD, 3 SEED)

Learning Rate	ANN	RNN	LSTM	GRU
10^{-4}	295,3 ± 4,6	285,0 ± 13,7	399,4 ± 25,0	398,4 ± 8,6
10^{-3}	**248,9 ± 8,9**	**206,1 ± 7,4**	230,5 ± 12,2	**207,5 ± 3,8**
10^{-2}	261,8 ± 16,6	226,7 ± 6,7	**215,9 ± 14,2**	208,2 ± 5,6

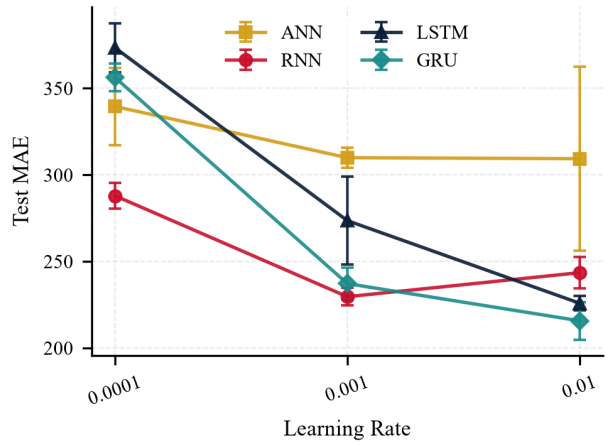


Fig. 6. Pengaruh variasi learning rate terhadap performa model.

Hasil komparasi laju pembelajaran menunjukkan dinamika optimasi sebagai berikut:

1) **Kegagalan Konvergensi pada Laju Terlalu Kecil ($\text{lr} = 10^{-4}$):** Pada nilai 10^{-4}, seluruh model (ANN, RNN, LSTM, GRU) menyentuh batas maksimum 300 epoch tanpa sekalipun memicu *early stopping* (rata-rata epoch tepat 300,0). Langkah pembaruan bobot yang terlampau lambat mengakibatkan model mengalami *severe underfitting* dan gagal mencapai lembah fungsi rugi dalam anggaran komputasi yang diberikan, sehingga val MAE melonjak sangat tinggi (LSTM $399,4 \pm 25,0$; GRU $398,4 \pm 8,6$; ANN $295,3$; RNN $285,0$).
2) **Keseimbangan Ideal pada Nilai Acuan ($\text{lr} = 10^{-3}$):** Nilai acuan 10^{-3} merupakan konfigurasi optimal bagi ANN ($248,9 \pm 8,9$), RNN ($206,1 \pm 7,4$), dan GRU ($207,5 \pm 3,8$). Pada nilai ini, mekanisme adaptif Adam berhasil memandu model menuju konvergensi stabil sebelum dihentikan oleh *early stopping* secara efisien pada epoch 106–194.
3) **Kecepatan Konvergensi dan Keunggulan pada Model Bergerbang ($\text{lr} = 10^{-2}$):** Pada laju besar 10^{-2}, seluruh arsitektur berkonvergensi secara sangat kilat, di mana *early stopping* menghentikan pelatihan hanya dalam 61–68 epoch. Menariknya, $\text{lr} = 10^{-2}$ menjadi konfigurasi terbaik bagi LSTM dengan penurunan val MAE signifikan ke level $\mathbf{215,9 \pm 14,2}$ (test MAE 225,8) serta mempertahankan performa prima pada GRU ($208,2 \pm 5,6$; test MAE 215,7). Ukuran langkah gradien yang lebih besar membantu mekanisme gerbang nonlinier sigmoid dan tanh keluar dengan cepat dari plateau jenuh pada awal inisialisasi bobot. Namun untuk Simple RNN tanpa gerbang, laju besar ini memicu sedikit instabilitas dan osilasi di sekitar kurva optimum sehingga val MAE sedikit terdegradasi ke $226,7 \pm 6,7$.

e) *A5. Pengaruh Kelompok Fitur Masukan:* [Laporkan faktor A5: net, net+call+sms, net+waktu, semua fitur. Tuliskan perbandingan val MAE dan interpretasi dampaknya.]

C. *Bagian B — Ablasi Pilihan*

[Jelaskan dua faktor tambahan pilihan kelompok (misalnya dropout dan horizon), hipotesis sebelum eksperimen, hasil pengukuran, dan apakah hasil mendukung hipotesis.]

D. *Bagian C — Konfigurasi Terbaik*

[Pilih konfigurasi terbaik tiap model berdasarkan validation MAE. Bandingkan performa pada minggu test dan periode Natal dengan konfigurasi acuan serta baseline naif.]

E. *Bagian D — Uji Generalisasi*

[Bandingkan konfigurasi acuan dan terbaik pada lokasi kelompok Navigli (Darsena), kotak 4555 (kode 1). Bahas perubahan urutan performa model dan kaitannya dengan pola trafik lokasi.]

IV. PEMBAHASAN

[Jelaskan mengapa hasil terjadi, faktor yang paling dan paling tidak berpengaruh, besarnya variasi antar-seed dibanding perbedaan model, dan keterbatasan studi.]

V. KESIMPULAN

[Tulis 3–5 kalimat yang menjawab tujuan studi dan merangkum temuan utama menggunakan angka hasil eksperimen.]

KONTRIBUSI ANGGOTA

Adif Dafa Raihan	[Isi kontribusi aktual, misalnya pendahuluan, metode, atau eksperimen.]
Cindy Auliya	[Isi kontribusi aktual, misalnya analisis hasil Bagian 0, A, dan B.]

Bima Cahya Ramadhan	[Isi kontribusi aktual, misalnya analisis Bagian C dan D, pembahasan, atau kesimpulan.]

Pernyataan Penggunaan AI

Kami menggunakan bantuan asisten AI, antara lain OpenCode, untuk membantu penulisan kode eksperimen, analisis awal, dan penyuntingan bahasa laporan. Seluruh rancangan eksperimen, eksekusi pelatihan, dan angka yang dilaporkan berasal dari run kelompok sendiri yang tersimpan pada hasil/ablasi.csv; setiap keluaran AI kami periksa ulang terhadap data tersebut. AI tidak dipakai untuk menghasilkan atau mengubah angka hasil.

Referensi

[1] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.

[2] K. Cho *et al.*, "Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1724–1734. doi: 10.3115/v1/D14-1179.

[3] G. Barlacchi *et al.*, "A multi-source dataset of urban life in the city of Milan and the Province of Trentino," *Scientific Data*, vol. 2, p. 150055, 2015, doi: 10.1038/sdata.2015.55.

[4] C. Zhang, S. Dang, B. Shihada, and M.-S. Alouini, "Dual Attention-Based Federated Learning for Wireless Traffic Prediction," in *IEEE INFOCOM 2021 – IEEE Conference on Computer Communications*, 2021, pp. 1–10. doi: 10.1109/INFOCOM42981.2021.9488883.

[5] A. Paszke *et al.*, "PyTorch: An Imperative Style, High-Performance Deep Learning Library," in *Advances in Neural Information Processing Systems 32 (NeurIPS)*, 2019, pp. 8024–8035.