Studi Ablasi RNN, LSTM, dan GRU dibandingkan ANN untuk Prediksi Trafik Seluler Kota Milan

Adif Dafa Raihan
NIM 124400055
Teknik Telekomunikasi, ITERA
adif.124400055@student.itera.ac.id

Cindy Auliya
NIM 124400045
Teknik Telekomunikasi, ITERA
cindy.124400045@student.itera.ac.id

Bima Cahya Ramadhan
NIM 124400001
Teknik Telekomunikasi, ITERA
bima.124400001@student.itera.ac.id

Abstract*—Pertumbuhan trafik internet seluler menuntut operator meramalkan beban setiap sel secara akurat agar kapasitas dan energi jaringan dialokasikan secara efisien. Penelitian ini membandingkan ANN dengan RNN, LSTM, dan GRU untuk prediksi trafik per jam pada dataset Telecom Italia Big Data Challenge di Milan, dengan lokasi utama Duomo (kotak 5060) dan uji generalisasi di Navigli (kotak 4555). Kami melakukan studi ablasi terkontrol dengan mengubah satu faktor setiap kali, yaitu panjang jendela, ukuran hidden, jumlah lapisan, learning rate, kelompok fitur, dropout, dan horizon, masing-masing dengan tiga random seed. Konfigurasi dipilih hanya berdasarkan val MAE, lalu diuji pada minggu test dan periode Natal. Pada konfigurasi acuan, RNN memberikan test MAE terbaik (229,6 $\pm$ 5,1) dan mengungguli baseline naif minggu lalu (467,6), sedangkan ANN terlemah di antara empat model (309,9 $\pm$ 5,9). Penyetelan menurunkan MAE RNN menjadi 224,5 dan LSTM dari 273,6 menjadi 225,3, tetapi konfigurasi terbaik GRU justru memburuk (239,7 versus 237,2) karena overfit. Di Navigli urutan berubah dan ANN menjadi terbaik (191,1 $\pm$ 1,9). Hasil ini menunjukkan bahwa keunggulan model sekuensial bergantung pada lokasi dan bahwa pemilihan hyperparameter berbasis validasi tidak selalu menjamin perbaikan pada data uji.

***Index Terms*—prediksi trafik seluler, RNN, LSTM, GRU, studi ablasi**

I. Pendahuluan

Pertumbuhan trafik data seluler menuntut operator meramalkan permintaan tiap sel secara akurat untuk alokasi kapasitas, efisiensi energi, dan kualitas layanan. Peramalan yang terlalu rendah menyebabkan kongesti, sedangkan peramalan yang terlalu tinggi membuang kapasitas. Karena trafik mengikuti ritme harian, mingguan, dan karakter kawasan, model perlu menangkap dependensi temporal, bukan hanya hubungan antarfitur pada satu waktu.

ANN meratakan jendela observasi sehingga urutan waktu hilang. Recurrent neural network (RNN) mempertahankan hidden state, tetapi rentan terhadap vanishing gradient. Long short-term memory (LSTM) menambahkan gerbang input, forget, dan output serta cell state [1], sedangkan gated recurrent unit (GRU) menyederhanakannya menjadi gerbang reset dan update [2]. Keunggulan model sekuensial tidak otomatis karena bergantung pada panjang jendela, kapasitas hidden, kedalaman, learning rate, fitur, regularisasi, dan horizon. Studi ablasi yang mengubah satu faktor setiap kali memisahkan pengaruh faktor tersebut dari variasi antar-seed.

Kontribusi laporan ini ada tiga. Pertama, ablasi terkontrol lima faktor utama (panjang jendela, ukuran hidden, jumlah lapisan, learning rate, kelompok fitur) dan dua faktor tambahan (dropout, horizon) pada empat model dengan tiga seed di Duomo. Kedua, pemilihan konfigurasi hanya dari val MAE, lalu evaluasi pada minggu test dan Natal bersama baseline naif. Ketiga, uji generalisasi konfigurasi acuan dan terbaik di Navigli (kotak 4555, kode 1).

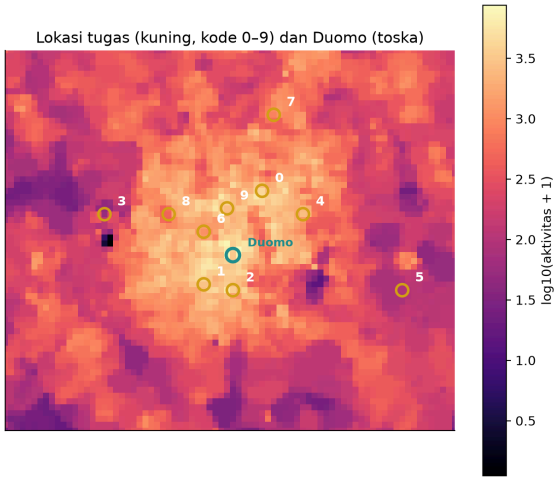


Fig. 1. Rata-rata aktivitas internet per kotak di Milan. Lingkaran kuning menunjukkan lokasi tugas (kode 0–9); lingkaran toska menunjukkan Duomo.

II. Data dan Metode

A. Dataset

Data berasal dari Telecom Italia Big Data Challenge [3] yang mencakup aktivitas jaringan di Kota Milan, Italia. Kami memakai versi agregasi per jam [4] untuk periode 4 November–29 Desember 2013, sehingga setiap lokasi memiliki 1.344 observasi atau 56 hari. Setiap catatan memuat tiga kanal trafik, yaitu internet (net), panggilan (call), dan SMS (sms). Fitur masukan berjumlah tujuh: net, call, sms, serta empat fitur waktu berupa sinus dan kosinus jam (jam_sin, jam_cos) dan hari (hari_sin, hari_cos). Fitur waktu merepresentasikan periodisitas sirkadian dan mingguan secara kontinu. Target peramalan adalah net satu jam ke depan.

Lokasi utama penelitian adalah kotak Duomo 5060 yang mewakili pusat aktivitas kota. Sebagai uji generalisasi, kami memakai lokasi kelompok, yaitu Navigli (Darsena) pada kotak 4555 dengan kode lokasi 1. Sebaran kedua lokasi ditunjukkan pada Fig. 1.

B. Pembagian Data dan Praproses

Pembagian data dilakukan secara kronologis: train 11 November–8 Desember 2013 (672 jam), validasi 9–15 Desember, test 16–22 Desember, dan periode Natal 23–29 Desember. Minggu pertama, 4–10 November, tidak dipakai sebagai sampel latih dan hanya menjadi konteks jendela bagi sampel awal. Pembagian ini memisahkan masa depan dari masa lalu sehingga tidak ada informasi test yang bocor ke pelatihan.

Standardisasi z-score dihitung dari rata-rata dan simpangan baku data sebelum 9 Desember, yaitu data latih beserta minggu konteks. Statistik tersebut kemudian diterapkan pada validasi, test, dan Natal. Dengan cara ini, model tidak pernah melihat statistik periode evaluasi. Jendela masukan dibentuk dengan panjang $W = 24$ jam dan horizon $H = 1$ jam, sehingga terdapat 672 jendela latih. Sebuah jendela dimasukkan ke split tertentu berdasarkan waktu targetnya, bukan waktu awal jendela. Prediksi dikembalikan ke skala asli sebelum metrik dihitung.

Data deret waktu tidak diacak pada tahap pembagian karena pengacakan akan mencampur masa lalu dan masa depan serta merusak urutan yang menjadi objek peramalan. Pengacakan hanya dilakukan pada urutan mini-batch selama pelatihan; setiap jendela tetap mempertahankan urutan internalnya.

C. Model dan Konfigurasi Acuan

ANN meratakan jendela $W \times 7$ menjadi vektor dan memetakannya melalui dua lapisan tersembunyi berukuran 32 dengan aktivasi ReLU. Model ini tidak memodelkan urutan secara eksplisit. RNN sederhana memproses jendela langkah demi langkah dengan hidden state berukuran 68 dan memakai state terakhir untuk prediksi. LSTM memakai hidden state 33 serta tiga gerbang dan cell state [1], sedangkan GRU memakai hidden state 38 dengan dua gerbang [2]. Pada ketiga model rekuren, keluaran diambil dari hidden state langkah terakhir, lalu dilewatkan satu lapisan linear.

Semua model dilatih dengan fungsi loss MSE dan optimizer Adam (learning rate 10^{-3}), batch 64, serta early stopping pada val MSE dengan patience 30 dan maksimum 300 epoch. Bobot terbaik dipilih dari epoch dengan val MSE terendah. Pelatihan diimplementasikan dengan PyTorch [5]. Konfigurasi acuan dirangkum pada Tabel I.

D. Protokol Ablasi dan Evaluasi

Setiap eksperimen mengubah satu faktor dari konfigurasi acuan, sedangkan faktor lain dipertahankan. Faktor A1 menguji panjang jendela $W \in \{6, 12, 24, 48, 168\}$ jam; A2 ukuran hidden $\{16, 32, 64, 128\}$; A3 jumlah lapisan $\{1, 2, 3\}$; A4 learning rate $\{10^{-4}, 10^{-3}, 10^{-2}\}$; dan A5 kelompok fitur {net, net+call+sms, net+waktu, semua}. Dua faktor tambahan adalah B2 dropout {0; 0,2; 0,5} dan B6 horizon {1, 6, 24} jam. Setiap konfigurasi dilatih dengan tiga random seed, yaitu 0, 1, dan 2, lalu dilaporkan sebagai rata-rata ± simpangan baku.

Evaluasi memakai MAE, RMSE, dan MAPE pada skala asli. MAE menjadi metrik utama karena satuannya sama dengan aktivitas trafik, sedangkan MAPE memberi gambaran error relatif. Pemilihan konfigurasi terbaik hanya memakai val MAE; data test dan Natal tidak dipakai sampai evaluasi akhir. Konfigurasi terbaik tiap model kemudian digabungkan pada Bagian C dan diuji generalisasinya pada Bagian D.

Seluruh pelatihan dijalankan pada CPU dengan PyTorch. Sebanyak 270 pelatihan unik (348 catatan run karena beberapa konfigurasi acuan dipakai ulang) memerlukan total waktu 92,6 menit.

TABLE I
KONFIGURASI ACUAN DAN JUMLAH PARAMETER

Hyperparameter	**Nilai acuan**
Panjang jendela W	24 jam
Horizon	1 jam
Ukuran hidden	ANN 32, RNN 68, LSTM 33, GRU 38
Jumlah lapisan	ANN 2, rekuren 1
Fitur	net, call, sms, jam (sin/cos), hari (sin/cos) — 7 fitur
Jumlah parameter	ANN 6.497, RNN 5.305, LSTM 5.578, GRU 5.397
Optimizer, *learning rate*	Adam, 10^{-3}
Batch size	64
Early stopping	*patience* 30, maks. 300 epoch

TABLE II
TEMPLAT HASIL ABLASI: TEST MAE RATA-RATA ± SIMPANGAN BAKU DARI TIGA SEED. GANTI NILAI CONTOH DENGAN HASIL EKSPERIMEN.

W **(jam)**	**ANN**	**RNN**	**LSTM**	**GRU**
6	–	–	–	–
24	–	–	–	–
168	–	–	–	–

III. HASIL

A. Bagian 0 — Baseline Naif dan Acuan

[Bandingkan baseline naif (last value, yesterday, last week) dengan konfigurasi acuan pada lokasi Duomo. Sajikan metrik rata-rata dan simpangan baku dari tiga seed.]

B. Bagian A — Ablasi Wajib

[Laporkan faktor A1–A5: panjang jendela, hidden units, jumlah lapisan, learning rate, dan fitur. Untuk setiap faktor, tuliskan rentang nilai, hasil utama, serta interpretasi singkat. Rujuk grafik dan tabel yang relevan dari folder hasil/.]

C. Bagian B — Ablasi Pilihan

[Jelaskan dua faktor tambahan pilihan kelompok (misalnya dropout dan horizon), hipotesis sebelum eksperimen, hasil pengukuran, dan apakah hasil mendukung hipotesis.]

D. Bagian C — Konfigurasi Terbaik

[Pilih konfigurasi terbaik tiap model berdasarkan validation MAE. Bandingkan performa pada minggu test dan periode Natal dengan konfigurasi acuan serta baseline naif.]

E. Bagian D — Uji Generalisasi

[Bandingkan konfigurasi acuan dan terbaik pada lokasi kelompok Navigli (Darsena), kotak 4555 (kode 1). Bahas perubahan urutan performa model dan kaitannya dengan pola trafik lokasi.]

IV. Pembahasan

[Jelaskan mengapa hasil terjadi, faktor yang paling dan paling tidak berpengaruh, besarnya variasi antar-seed dibanding perbedaan model, dan keterbatasan studi.]

V. Kesimpulan

[Tulis 3–5 kalimat yang menjawab tujuan studi dan merangkum temuan utama menggunakan angka hasil eksperimen.]

Kontribusi Anggota

Adif Dafa Raihan	[Isi kontribusi aktual, misalnya pendahuluan, metode, atau eksperimen.]
Cindy Auliya	[Isi kontribusi aktual, misalnya analisis hasil Bagian 0, A, dan B.]
Bima Cahya Ramadhan	[Isi kontribusi aktual, misalnya analisis Bagian C dan D, pembahasan, atau kesimpulan.]

Pernyataan Penggunaan AI

Kami menggunakan bantuan asisten AI, antara lain OpenCode, untuk membantu penulisan kode eksperimen, analisis awal, dan penyuntingan bahasa laporan. Seluruh rancangan eksperimen, eksekusi pelatihan, dan angka yang dilaporkan berasal dari run kelompok sendiri yang tersimpan pada `hasil/ablasi.csv`; setiap keluaran AI kami periksa ulang terhadap data tersebut. AI tidak dipakai untuk menghasilkan atau mengubah angka hasil.

Referensi

[1] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.

[2] K. Cho *et al.*, "Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1724–1734. doi: 10.3115/v1/D14-1179.

[3] G. Barlacchi *et al.*, "A multi-source dataset of urban life in the city of Milan and the Province of Trentino," *Scientific Data*, vol. 2, p. 150055, 2015, doi: 10.1038/sdata.2015.55.

[4] C. Zhang, S. Dang, B. Shihada, and M.-S. Alouini, "Dual Attention-Based Federated Learning for Wireless Traffic Prediction," in *IEEE INFOCOM 2021 – IEEE Conference on Computer Communications*, 2021, pp. 1–10. doi: 10.1109/INFOCOM42981.2021.9488883.

[5] A. Paszke *et al.*, "PyTorch: An Imperative Style, High-Performance Deep Learning Library," in *Advances in Neural Information Processing Systems 32 (NeurIPS)*, 2019, pp. 8024–8035.