Studi Ablasi RNN, LSTM, dan GRU dibandingkan ANN untuk Prediksi Trafik Seluler Kota Milan

Adif Dafa Raihan
NIM 124400055
Teknik Telekomunikasi, ITERA
adif.124400055@student.itera.ac.id

Cindy Auliya
NIM 124400045
Teknik Telekomunikasi, ITERA
cindy.124400045@student.itera.ac.id

Bima Cahya Ramadhan
NIM 124400001
Teknik Telekomunikasi, ITERA
bima.124400001@student.itera.ac.id

Abstract*—Pertumbuhan trafik internet seluler menuntut operator meramalkan beban setiap sel secara akurat agar kapasitas dan energi jaringan dialokasikan secara efisien. Penelitian ini membandingkan ANN dengan RNN, LSTM, dan GRU untuk prediksi trafik per jam pada dataset Telecom Italia Big Data Challenge di Milan, dengan lokasi utama Duomo (kotak 5060) dan uji generalisasi di Navigli (kotak 4555). Kami melakukan studi ablasi terkontrol dengan mengubah satu faktor setiap kali, yaitu panjang jendela, ukuran hidden, jumlah lapisan, learning rate, kelompok fitur, dropout, dan horizon, masing-masing dengan tiga random seed. Konfigurasi dipilih hanya berdasarkan val MAE, lalu diuji pada minggu test dan periode Natal. Pada konfigurasi acuan, RNN memberikan test MAE terbaik (229,6 $\pm$ 5,1) dan mengungguli baseline naif minggu lalu (467,6), sedangkan ANN terlemah di antara empat model (309,9 $\pm$ 5,9). Penyetelan menurunkan MAE RNN menjadi 224,5 dan LSTM dari 273,6 menjadi 225,3, tetapi konfigurasi terbaik GRU justru memburuk (239,7 versus 237,2) karena overfit. Di Navigli urutan berubah dan ANN menjadi terbaik (191,1 $\pm$ 1,9). Hasil ini menunjukkan bahwa keunggulan model sekuensial bergantung pada lokasi dan bahwa pemilihan hyperparameter berbasis validasi tidak selalu menjamin perbaikan pada data uji.

***Index Terms*—GRU, LSTM, prediksi trafik seluler, RNN, studi ablasi**

I. Pendahuluan

Pertumbuhan trafik data seluler menuntut operator meramalkan permintaan tiap sel secara akurat untuk alokasi kapasitas, efisiensi energi, dan kualitas layanan. Peramalan yang terlalu rendah menyebabkan kongesti, sedangkan peramalan yang terlalu tinggi membuang kapasitas. Karena trafik mengikuti ritme harian, mingguan, dan karakter kawasan, model perlu menangkap dependensi temporal, bukan hanya hubungan antarfitur pada satu waktu.

ANN meratakan jendela observasi sehingga urutan waktu hilang. Recurrent neural network (RNN) mempertahankan hidden state, tetapi rentan terhadap vanishing gradient. Long short-term memory (LSTM) menambahkan gerbang input, forget, dan output serta cell state [1], sedangkan gated recurrent unit (GRU) menyederhanakannya menjadi gerbang reset dan update [2]. Keunggulan model sekuensial tidak otomatis karena bergantung pada panjang jendela, kapasitas hidden, kedalaman, learning rate, fitur, regularisasi, dan horizon. Studi ablasi yang mengubah satu faktor setiap kali memisahkan pengaruh faktor tersebut dari variasi antar-seed.

Kontribusi laporan ini ada tiga. Pertama, ablasi terkontrol lima faktor utama (panjang jendela, ukuran hidden, jumlah lapisan, learning rate, kelompok fitur) dan dua faktor tambahan (dropout, horizon) pada empat model dengan tiga seed di Duomo. Kedua, pemilihan konfigurasi hanya dari val MAE, lalu evaluasi pada minggu test dan Natal bersama baseline naif. Ketiga, uji generalisasi konfigurasi acuan dan terbaik di Navigli (kotak 4555, kode 1).

II. Data dan Metode

A. Dataset

Data berasal dari Telecom Italia Big Data Challenge [3] yang mencakup aktivitas jaringan di Kota Milan, Italia. Kami memakai versi agregasi per jam [4] untuk periode 4 November–29 Desember 2013, sehingga setiap lokasi memiliki 1.344 observasi atau 56 hari. Setiap catatan memuat tiga kanal trafik, yaitu internet (net), panggilan (call), dan SMS (sms). Fitur masukan berjumlah tujuh: net, call, sms, serta empat fitur waktu berupa sinus dan kosinus jam (jam_sin, jam_cos) dan hari (hari_sin, hari_cos). Fitur waktu merepresentasikan periodisitas sirkadian dan mingguan secara kontinu. Target peramalan adalah net satu jam ke depan. Lokasi utama penelitian adalah kotak Duomo 5060, sedangkan lokasi kelompok untuk uji generalisasi adalah Navigli (Darsena), kotak 4555 dengan kode lokasi 1.

B. Pembagian Data dan Praproses

Pembagian data dilakukan secara kronologis: train 11 November–8 Desember 2013 (672 jam), validasi 9–15 Desember, test 16–22 Desember, dan periode Natal 23–29 Desember. Minggu pertama, 4–10 November, hanya menjadi konteks jendela bagi sampel awal. Pembagian ini memisahkan masa depan dari masa lalu sehingga tidak ada informasi test yang bocor ke pelatihan.

Standardisasi z-score dihitung dari rata-rata dan simpangan baku data sebelum 9 Desember, yaitu data latih beserta minggu konteks. Statistik tersebut kemudian diterapkan pada validasi, test, dan Natal. Jendela masukan dibentuk dengan panjang $W = 24$ jam dan horizon $H = 1$ jam, sehingga terdapat 672 jendela latih. Sebuah jendela dimasukkan ke split berdasarkan waktu targetnya, bukan waktu awal jendela. Prediksi dikembalikan ke skala asli sebelum metrik dihitung.

Deret waktu tidak diacak pada tahap pembagian karena pengacakan akan mencampur masa lalu dan masa depan serta merusak urutan yang menjadi objek peramalan. Pengacakan hanya dilakukan pada urutan mini-batch selama pelatihan; setiap jendela tetap mempertahankan urutan internalnya.

TABLE I
KONFIGURASI ACUAN DAN JUMLAH PARAMETER

Hyperparameter	Nilai acuan
Panjang jendela W	24 jam
Horizon	1 jam
Ukuran hidden	ANN 32, RNN 68, LSTM 33, GRU 38
Jumlah lapisan	ANN 2, rekuren 1
Fitur	net, call, sms, jam (sin/cos), hari (sin/cos) — 7 fitur
Jumlah parameter	ANN 6.497, RNN 5.305, LSTM 5.578, GRU 5.397
Optimizer, *learning rate*	Adam, 10^{-3}
Batch size	64
Early stopping	*patience* 30, maks. 300 epoch

C. Model dan Konfigurasi Acuan

ANN meratakan jendela $W \times 7$ menjadi vektor dan memetakannya melalui dua lapisan tersembunyi berukuran 32 dengan aktivasi ReLU. RNN sederhana memakai hidden state 68, LSTM memakai hidden state 33 dengan tiga gerbang dan cell state [1], sedangkan GRU memakai hidden state 38 dengan dua gerbang [2]. Pada ketiga model rekuren, keluaran diambil dari hidden state langkah terakhir, lalu dilewatkan satu lapisan linear.

Semua model dilatih dengan loss MSE dan optimizer Adam (learning rate 10^{-3}), batch 64, serta early stopping pada val MSE dengan patience 30 dan maksimum 300 epoch. Bobot terbaik dipilih dari epoch dengan val MSE terendah. Pelatihan diimplementasikan dengan PyTorch [5]. Konfigurasi acuan dirangkum pada Tabel I.

D. Protokol Ablasi dan Evaluasi

Setiap eksperimen mengubah satu faktor dari konfigurasi acuan. Faktor A1 menguji $W \in \{6, 12, 24, 48, 168\}$ jam; A2 ukuran hidden $\{16, 32, 64, 128\}$; A3 jumlah lapisan $\{1, 2, 3\}$; A4 learning rate $\{10^{-4}, 10^{-3}, 10^{-2}\}$; dan A5 kelompok fitur {net, net+call+sms, net+waktu, semua}. Faktor tambahan adalah B2 dropout {0; 0,2; 0,5} dan B6 horizon {1, 6, 24} jam. Setiap konfigurasi dilatih dengan tiga seed (0, 1, 2) dan dilaporkan sebagai rata-rata $\pm$ simpangan baku.

Evaluasi memakai MAE, RMSE, dan MAPE pada skala asli; MAE menjadi metrik utama. Pemilihan konfigurasi terbaik hanya memakai val MAE, sedangkan data test dan Natal dipakai untuk evaluasi akhir. Seluruh pelatihan dijalankan pada CPU dengan PyTorch; 270 pelatihan unik (348 catatan run karena beberapa konfigurasi acuan dipakai ulang) memerlukan total 92,6 menit.

III. HASIL

A. Bagian 0 — Baseline Naif dan Acuan

Evaluasi diawali dengan membandingkan empat model pada konfigurasi acuan dengan tiga baseline naif di Duomo (kotak 5060) untuk horizon satu jam. Baseline tersebut adalah nilai terakhir, nilai kemarin ($t - 24$), dan nilai minggu lalu ($t - 168$). Seluruh nilai model dilaporkan sebagai rata-rata $\pm$ simpangan baku dari tiga seed (0, 1, 2) pada Tabel II.

TABLE II
BASELINE NAIF DAN KONFIGURASI ACUAN DI DUOMO ($H = 1$ JAM, RATA-RATA $\pm$ SIMPANGAN BAKU, 3 SEED)

Metode / Model	Param	Val MAE	Test MAE	Test MAPE	Natal MAE
Naif: nilai terakhir	0	662,6	600,9	18,4%	431,2
Naif: kemarin	0	595,3	552,2	23,8%	921,5
Naif: minggu lalu	0	492,8	467,6	19,9%	1.426,2
ANN (Acuan)	6.497	248,9 $\pm$ 8,9	309,9 $\pm$ 5,9	11,3 $\pm$ 0,8%	680,1 $\pm$ 52,0
RNN (Acuan)	5.305	206,1 $\pm$ 7,4	229,6 $\pm$ 5,1	8,5 $\pm$ 0,3%	421,2 $\pm$ 2,4
LSTM (Acuan)	5.578	230,5 $\pm$ 12,2	273,6 $\pm$ 25,4	9,1 $\pm$ 1,0%	586,0 $\pm$ 56,8
GRU (Acuan)	5.397	207,5 $\pm$ 3,8	237,2 $\pm$ 9,3	8,0 $\pm$ 0,7%	468,2 $\pm$ 21,8

Pada minggu test, baseline terbaik adalah naif minggu lalu (467,6), diikuti naif kemarin (552,2) dan nilai terakhir (600,9). Seluruh model mengungguli baseline tersebut: RNN mencapai test MAE 229,6 $\pm$ 5,1 (50,9% lebih rendah), disusul GRU 237,2 $\pm$ 9,3, LSTM 273,6 $\pm$ 25,4, dan ANN 309,9 $\pm$ 5,9. MAPE model berada pada 8,0%–11,3%, jauh di bawah baseline (18,4%–23,8%). Pada minggu Natal, RNN tetap paling tangguh (421,2 $\pm$ 2,4) dan sedikit lebih baik dari naif nilai terakhir (431,2), sedangkan ANN (680,1) dan LSTM (586,0) mengalami degradasi terbesar. Pola ini menunjukkan bahwa keunggulan model rekuren muncul baik pada kondisi reguler maupun saat terjadi pergeseran distribusi.

B. Bagian A — Ablasi Wajib

Ablasi dilakukan dengan protokol satu faktor pada satu waktu dari konfigurasi acuan (Tabel I). Setiap konfigurasi dijalankan dengan tiga seed, dan pemilihan nilai terbaik memakai val MAE; tabel serta gambar pada bagian ini menampilkan test MAE untuk melihat transfer ke data uji.

a) *A1. Pengaruh Panjang Jendela Observasi (W):*

Eksperimen A1 memvariasikan $W \in \{6, 12, 24, 48, 168\}$ jam. Hasil test MAE disajikan pada Tabel III; sel tebal menandai konfigurasi yang dipilih berdasarkan val MAE.

TABLE III
PENGARUH PANJANG JENDELA W (JAM) TERHADAP TEST MAE (RATA-RATA ± SD, 3 SEED). SEL TEBAL = KONFIGURASI TERPILIH BERDASARKAN VAL MAE.

W (jam)	ANN	RNN	LSTM	GRU
6	**269,4 ± 16,8**	228,6 ± 5,4	**276,4 ± 14,7**	249,8 ± 1,4
12	308,8 ± 11,6	233,2 ± 11,2	302,7 ± 17,4	246,1 ± 13,5
24	309,9 ± 5,9	229,6 ± 5,1	273,6 ± 25,4	237,2 ± 9,3
48	333,1 ± 20,2	**224,5 ± 11,7**	304,4 ± 27,1	**237,1 ± 10,6**
168	402,0 ± 12,5	233,5 ± 4,8	292,8 ± 20,0	237,2 ± 10,6

ANN sangat sensitif terhadap W: test MAE naik dari 269,4 pada $W = 6$ menjadi 402,0 pada $W = 168$, seiring pertumbuhan parameter dari 2.465 menjadi 38.753. Val MAE juga memilih $W = 6$ (211,5 ± 6,2). Sebaliknya, RNN dan GRU relatif stabil karena jumlah parameternya konstan; keduanya optimum pada $W = 48$ dengan test MAE 224,5 ± 11,7 dan 237,1 ± 10,6. LSTM memilih $W = 6$ berdasarkan val (227,1 ± 4,3), tetapi pada test nilai terendah justru $W = 24$ (273,6 ± 25,4), hanya 2,8 lebih rendah dari $W = 6$. Perbedaan kecil ini menunjukkan bahwa pemilihan berbasis val tidak selalu transfer sempurna ke test.

b) *A2. Pengaruh Ukuran Hidden:*

Ukuran hidden $\{16, 32, 64, 128\}$ diuji pada keempat model. Kapasitas 16 unit menyebabkan underfitting (val MAE 216,8–257,6), sedangkan 128 unit memberi val MAE terbaik pada semua model: ANN 233,8 ± 1,9, LSTM 207,1 ± 8,4, dan GRU 188,7 ± 4,2. Pada test, GRU 128 mencapai 220,3 dan LSTM 128 mencapai 245,6. RNN mencapai titik jenuh pada 64 unit (val 207,2 ± 12,8); menaikkannya ke 128 tidak memperbaiki hasil (207,7 ± 7,2). Peningkatan kapasitas juga membengkakkan parameter: LSTM 70.273, GRU 52.737, ANN 38.273, dan RNN 17.665. Dinamika test MAE ditunjukkan pada Fig. 1.

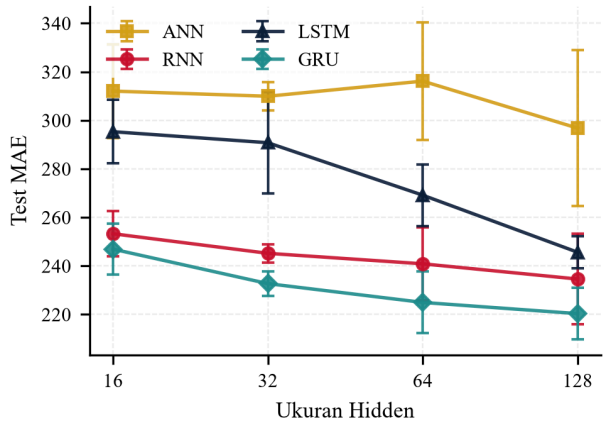


Fig. 1. Test MAE terhadap ukuran hidden di Duomo (rata-rata ± SD, 3 seed).

c) *A3. Pengaruh Jumlah Lapisan:*

Kedalaman $\{1, 2, 3\}$ lapisan memberi pengaruh berbeda per arsitektur. ANN hampir tidak berubah (val 240,9–248,9), sehingga penambahan lapisan tidak memberi abstraksi berarti. RNN terbaik pada satu lapisan (206,1 ± 7,4) dan memburuk pada tiga lapisan (225,1 ± 12,7). GRU terbaik pada dua lapisan (203,3 ± 9,6) dan sedikit menurun pada tiga lapisan (212,2 ± 15,9). Kasus terburuk terjadi pada LSTM tiga lapisan: val MAE melonjak dari 230,5 menjadi 338,9 ± 16,9 dan test MAE mencapai 412,6, konsisten dengan kesulitan propagasi gradien pada tumpukan gerbang.

d) *A4. Pengaruh Learning Rate:*

Learning rate $\{10^{-4}, 10^{-3}, 10^{-2}\}$ menguji stabilitas optimasi Adam. Pada 10^{-4}, seluruh model menyentuh 300 epoch tanpa early stopping dan mengalami underfitting (val 285,0–399,4). Nilai 10^{-3} optimal bagi ANN (248,9), RNN (206,1), dan GRU (207,5). Sebaliknya, LSTM dan GRU bergerbang lebih cepat keluar dari plateau pada 10^{-2}: LSTM mencapai val 215,9 ± 14,2 (test 225,8) dan GRU test 215,7, sedangkan RNN justru sedikit memburuk (val 226,7). Dengan demikian, laju kecil menghambat konvergensi, sedangkan laju besar hanya menguntungkan model bergerbang. Tren test MAE antar-learning rate ditunjukkan pada Fig. 2.

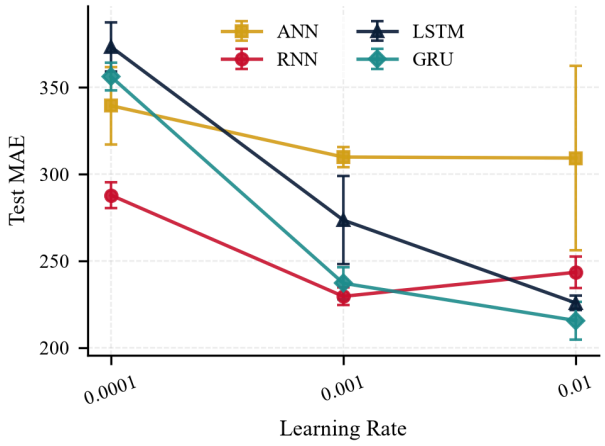


Fig. 2. Test MAE terhadap learning rate di Duomo (rata-rata ± SD, 3 seed).

e) *A5. Pengaruh Kelompok Fitur:*

Empat kelompok fitur diuji: net, net+call+sms, net+waktu, dan semua fitur. Kelompok net saja memberi val MAE tertinggi untuk RNN (245,2), LSTM (266,2), dan GRU (264,6), dengan test MAE 254,1–284,1. Penambahan call+sms menurunkan val dan test RNN menjadi 224,1 dan 227,6, serta LSTM menjadi 243,7 dan 262,7. Fitur waktu memberi perbaikan val terbesar pada ANN (260,5 menjadi 246,0) dan GRU (264,6 menjadi 213,2); pada test, GRU membaik dari 270,5 menjadi 239,7, tetapi ANN justru memburuk dari 271,8 menjadi 296,4. Kelompok semua fitur memberi val MAE terbaik untuk RNN (206,1), LSTM (230,5), dan GRU (207,5), serta test GRU terbaik (237,2). Tidak ada satu kelompok yang unggul mutlak: fitur waktu dan kanal call/sms sama-sama berguna, dan ANN paling sensitif terhadap penambahan fitur. Perbandingan test MAE keempat kelompok fitur disajikan pada Fig. 3.

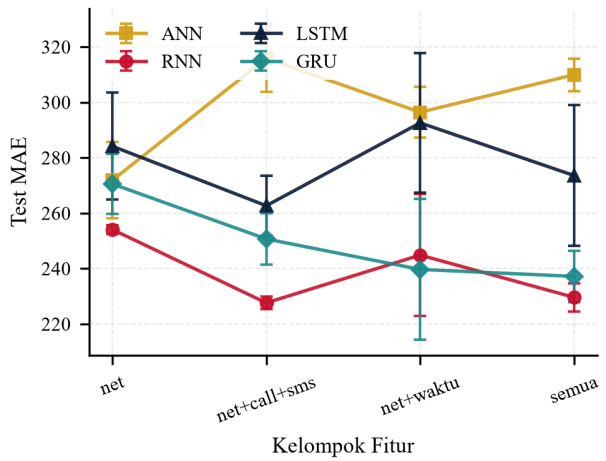


Fig. 3. Test MAE untuk empat kelompok fitur di Duomo (rata-rata ± SD, 3 seed).

C. Bagian B — Ablasi Pilihan

Dua faktor tambahan diuji dengan tiga seed: dropout (B2) dan horizon peramalan (B6).

a) *B2. Dropout:*

Hipotesis awal: dropout moderat ($p = 0,2$) meningkatkan generalisasi, sedangkan $p = 0,5$ menyebabkan underfitting. Hasilnya, $p = 0,2$ menurunkan test MAE GRU dari 237,2 menjadi 225,0 (Natal 468,2 menjadi 429,7) dan val MAE dari 207,5 menjadi 203,9; LSTM juga membaik pada test (273,6 menjadi 264,6). Namun, ANN memburuk dari 309,9 menjadi 330,3 dan RNN dari 229,6 menjadi 260,3. Pada $p = 0,5$, seluruh model memburuk (test MAE ANN 411,6, RNN 260,2, LSTM 289,1, GRU 273,6). Hipotesis hanya sebagian didukung: manfaat dropout terbatas pada model bergerbang, terutama GRU, sedangkan underfitting pada dropout agresif terbukti pada semua model. Perbandingan test MAE antar-tingkat dropout ditunjukkan pada Fig. 4.

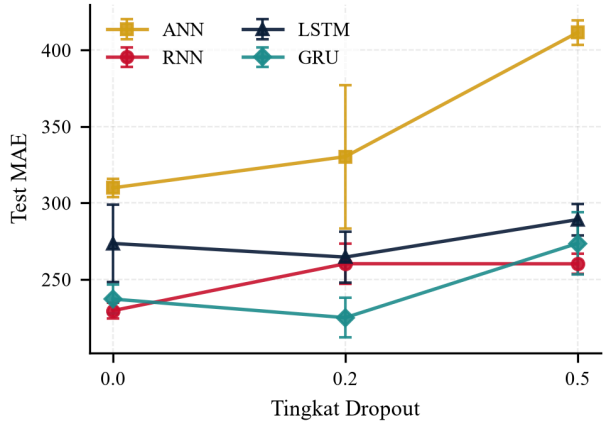


Fig. 4. Test MAE terhadap tingkat dropout pada empat model di Duomo (rata-rata ± SD, 3 seed).

b) *B6. Horizon Peramalan:*

Hipotesis awal: MAE meningkat monoton seiring horizon, keunggulan terhadap baseline mengecil pada horizon panjang, dan model rekuren lebih baik daripada ANN. Hasil test MAE meningkat dari 229,6–309,9 pada $H = 1$ menjadi 395,7–433,4 pada $H = 6$, lalu 486,4–526,8 pada $H = 24$; seluruh model pada $H = 24$ kalah dari baseline naif minggu lalu (466,1). Pada $H = 24$, model rekuren (486,4–503,3) mengungguli ANN (526,8), meskipun pada $H = 6$ ANN justru yang terbaik (395,7). MAE Natal pada $H = 24$ memburuk ke 1.101,6–1.199,4. Tren ini ditunjukkan pada Fig. 5, dan hipotesis didukung sepenuhnya.

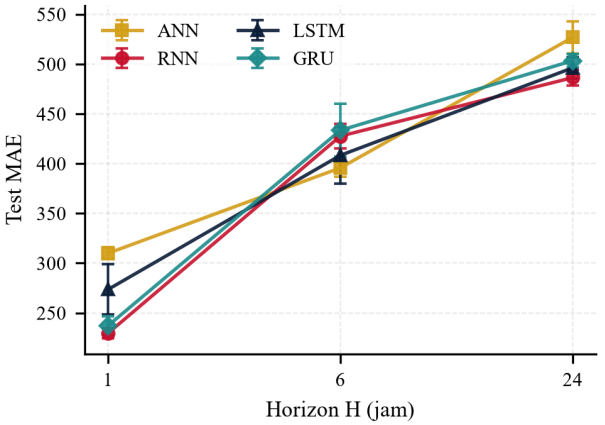


Fig. 5. Test MAE terhadap horizon peramalan pada empat model di Duomo (rata-rata ± SD, 3 seed).

D. Bagian C — Konfigurasi Terbaik

Konfigurasi terbaik tiap model dipilih hanya dari val MAE, lalu dievaluasi pada minggu test dan Natal. Kombinasi terpilih adalah ANN dengan $W = 6$, hidden 128, 1 lapisan, dan fitur `net+waktu` (4.097 parameter); RNN dengan $W = 48$ (5.305 parameter); LSTM dengan $W = 6$, hidden 128, dan `lr` $= 10^{-2}$ (70.273 parameter); serta GRU dengan $W = 48$, hidden 128, 2 lapisan, dan dropout 0,2 (151.809 parameter). Hasil lengkapnya disajikan pada Tabel IV dan Fig. 6.

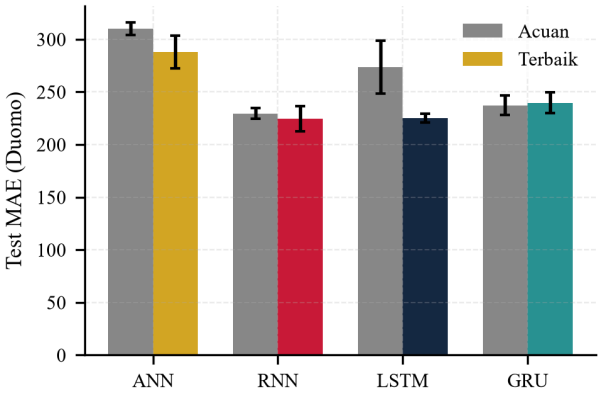


Fig. 6. Perbandingan test MAE antara konfigurasi acuan dan terbaik di Duomo (rata-rata ± SD, 3 seed).

Penyetelan menurunkan test MAE ANN menjadi 288,1 ± 15,6 (turun 7,0%), RNN menjadi 224,5 ± 11,7 (turun 2,2%), dan LSTM menjadi 225,3 ± 4,0 (turun 17,7%). LSTM juga mencatat MAPE terbaik (7,3 ± 0,7%). GRU terbaik justru mengalami degradasi pada test (239,7 versus 237,2) dan Natal

TABLE IV
PERBANDINGAN PERFORMA KONFIGURASI ACUAN DAN TERBAIK DI DUOMO ($H = 1$ JAM, RATA-RATA ± SD, 3 SEED). SEL TEBAL = NILAI TEST TERBAIK PER MODEL.

Model	Konfigurasi	Param	Val MAE	Test MAE	Test MAPE	Natal MAE
ANN	Acuan	6.497	248,9 ± 8,9	309,9 ± 5,9	11,3 ± 0,8%	680,1 ± 52,0
ANN	**Terbaik**	4.097	230,1 ± 14,8	**288,1 ± 15,6**	9,6 ± 0,6%	617,7 ± 36,0
RNN	Acuan	5.305	206,1 ± 7,4	229,6 ± 5,1	8,5 ± 0,3%	421,2 ± 2,4
RNN	**Terbaik**	5.305	200,1 ± 5,3	**224,5 ± 11,7**	8,2 ± 0,8%	404,5 ± 9,9
LSTM	Acuan	5.578	230,5 ± 12,2	273,6 ± 25,4	9,1 ± 1,0%	586,0 ± 56,8
LSTM	**Terbaik**	70.273	221,3 ± 6,9	**225,3 ± 4,0**	7,3 ± 0,7%	454,5 ± 36,4
GRU	Acuan	5.397	207,5 ± 3,8	**237,2 ± 9,3**	8,0 ± 0,7%	**468,2 ± 21,8**
GRU	Terbaik	151.809	203,6 ± 7,3	239,7 ± 9,9	7,9 ± 0,4%	497,6 ± 16,8

(497,6 versus 468,2), meskipun val MAE lebih rendah (203,6 versus 207,5); pertumbuhan parameter menjadi 151.809 memicu overfitting. RNN terbaik menjadi model paling akurat di Duomo, dan pada Natal RNN terbaik mencatat 404,5 ± 9,9, lebih baik dari seluruh baseline. Semua konfigurasi tetap mengungguli baseline naif minggu lalu (467,6).

E. Bagian D — Uji Generalisasi

Uji generalisasi dilakukan pada Navigli (Darsena), kotak 4555 kode 1, dengan konfigurasi acuan dan terbaik yang sama (Tabel V dan Fig. 7). Navigli adalah kawasan hiburan malam dengan lonjakan trafik pada pukul 20.00–03.00 dan akhir pekan, berbeda dari pola perkantoran Duomo.

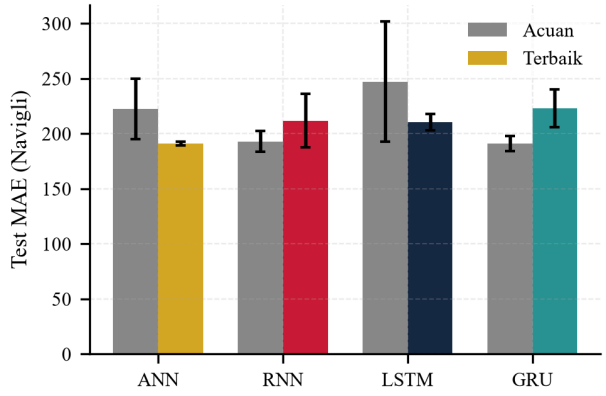


Fig. 7. Test MAE konfigurasi acuan dan terbaik di Navigli (rata-rata ± SD, 3 seed).

Urutan model berubah total. Di Duomo, urutan test MAE acuan adalah RNN (229,6) < GRU (237,2) < LSTM (273,6) < ANN (309,9); di Navigli urutannya GRU (190,8) < RNN (193,0) < ANN (222,3) < LSTM (247,3). Setelah penyetelan,

TABLE V
EVALUASI GENERALISASI DI NAVIGLI, KOTAK 4555 ($H = 1$ JAM, RATA-RATA ± SD, 3 SEED).

Model	Konfigurasi	Param	Val MAE	Test MAE	Test MAPE	Natal MAE
ANN	Acuan	6.497	166,6 ± 5,3	222,3 ± 27,4	8,9 ± 1,1%	664,5 ± 190,8
ANN	**Terbaik**	4.097	138,4 ± 1,7	**191,1 ± 1,9**	7,9 ± 0,1%	607,7 ± 56,1
RNN	Acuan	5.305	147,3 ± 4,9	**193,0 ± 9,7**	7,8 ± 0,3%	534,7 ± 148,9
RNN	Terbaik	5.305	148,7 ± 7,7	211,7 ± 24,3	8,7 ± 1,0%	649,2 ± 92,5
LSTM	Acuan	5.578	164,3 ± 9,3	247,3 ± 54,3	10,0 ± 2,7%	950,8 ± 110,9
LSTM	**Terbaik**	70.273	147,2 ± 4,2	**210,4 ± 7,7**	8,5 ± 0,5%	738,4 ± 41,9
GRU	Acuan	5.397	149,0 ± 6,0	**190,8 ± 6,8**	7,8 ± 0,2%	496,4 ± 50,9
GRU	Terbaik	151.809	132,5 ± 2,1	223,1 ± 17,0	9,6 ± 0,7%	753,7 ± 49,8

ANN terbaik menjadi model nomor satu di Navigli (191,1 ± 1,9), disusul LSTM (210,4), RNN (211,7), dan GRU (223,1). Konfigurasi terbaik RNN dan GRU yang memakai $W = 48$ justru memburuk di Navigli, sedangkan ANN dan LSTM yang memakai $W = 6$ membaik. Jendela pendek lebih sesuai untuk dinamika nightlife yang impulsif; jendela 48 jam membawa histori hari kerja yang tidak relevan sehingga mengaburkan lonjakan akhir pekan. Pada Natal, naif nilai terakhir (177,7) menjadi pembanding terkuat karena aktivitas malam surut dan relatif datar, sementara model deep learning cenderung memprediksi lonjakan yang tidak terjadi.

IV. PEMBAHASAN

Hasil menunjukkan bahwa keunggulan arsitektur tidak universal, tetapi bergantung pada sifat temporal kawasan. Di Duomo yang relatif stasioner dan mengikuti ritme kerja mingguan, hidden state rekuren menangkap dependensi jangka panjang secara efisien. Di Navigli yang impulsif, memori panjang justru menjadi beban; ANN dengan jendela pendek dan fitur waktu deterministik lebih adaptif.

Faktor paling berpengaruh adalah ukuran hidden dan learning rate. Kapasitas 16 unit underfit, sedangkan 128 unit menurunkan error secara konsisten tetapi memperbesar parameter hingga 70.273 (LSTM) dan 52.737 (GRU). Learning rate 10^{-4} gagal konvergen, sedangkan 10^{-2} hanya menguntungkan model bergerbang. Panjang jendela kritis bagi ANN karena parameter tumbuh dari 2.465 menjadi 38.753; kedalaman LSTM tiga lapis juga katastrofik (val 338,9; test 412,6). Sebaliknya, kedalaman ANN dan penambahan call/sms pada ANN memberi perubahan kecil.

Perbedaan antar-model umumnya lebih besar daripada variasi antar-seed. Selisih RNN dan ANN acuan di Duomo mencapai 80,3 poin, jauh di atas simpangan baku seed (5,1–25,4). Namun, model berkapasitas besar seperti LSTM di

Navigli ($\pm$ 54,3) dan ANN di Navigli ($\pm$ 27,4) memiliki variansi lebar, sehingga evaluasi multi-seed tetap diperlukan. Keterbatasan studi meliputi cakupan dua kotak di Milan, 56 hari data, satu pembagian kronologis, dan tidak adanya sampel libur panjang pada data latih.

V. Kesimpulan

Studi ablasi ini menunjukkan bahwa RNN, LSTM, dan GRU mengungguli ANN dan baseline naif di Duomo, dengan test MAE acuan RNN 229,6 $\pm$ 5,1 dibandingkan ANN 309,9 $\pm$ 5,9 dan naif minggu lalu 467,6. Penyetelan berbasis val MAE menurunkan error LSTM menjadi 225,3 $\pm$ 4,0 dan RNN menjadi 224,5 $\pm$ 11,7, tetapi GRU terbaik (151.809 parameter) overfit dan sedikit memburuk pada test (239,7). Di Navigli, urutan model berbalik: ANN terbaik dengan $W = 6$ menjadi yang paling akurat (191,1 $\pm$ 1,9). Temuan ini menegaskan bahwa pemilihan arsitektur dan hyperparameter harus mempertimbangkan karakter temporal lokasi, serta regularisasi diperlukan agar kapasitas besar tidak menghafal pola validasi.

Kontribusi Anggota

Adif Dafa Raihan	Kerangka proyek dan README, eksperimen Bagian 0 dan A1, pelatihan Bagian C/D, tabel pemilihan faktor, Abstrak, Pendahuluan, Metode, analisis A5/B2/B6, verifikasi angka, dan integrasi laporan.
Cindy Auliya	Hipotesis dan evaluasi Bagian B, eksperimen A3, A4, B2, dan B6, serta analisis hasil Bagian 0 dan A1–A4.
Bima Cahya Ramadhan	Eksperimen A2 dan A5, evaluasi Bagian C/D, grafik dan tabel IEEE, serta penulisan Bagian C, Bagian D, Pembahasan, dan Kesimpulan.

Pernyataan Penggunaan AI

Alat AI yang kami gunakan adalah Antigravity CLI, Copilot CLI, OpenCode CLI, Gemini (model LLM), Copilot (model LLM), dan DeepSeek (model). Alat-alat tersebut digunakan untuk membantu penulisan kode eksperimen, analisis awal, dan penyuntingan bahasa laporan. Seluruh rancangan eksperimen, eksekusi pelatihan, dan angka yang dilaporkan berasal dari run kelompok sendiri yang tersimpan pada `hasil/ablasi.csv`; setiap keluaran AI kami periksa ulang terhadap data tersebut. AI tidak dipakai untuk menghasilkan atau mengubah angka hasil.

Laporan ini disusun dan dikompilasi menggunakan Typst.

Referensi

[1] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.

[2] K. Cho *et al.*, "Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1724–1734. doi: 10.3115/v1/D14-1179.

[3] G. Barlacchi *et al.*, "A multi-source dataset of urban life in the city of Milan and the Province of Trentino," *Scientific Data*, vol. 2, p. 150055, 2015, doi: 10.1038/sdata.2015.55.

[4] C. Zhang, S. Dang, B. Shihada, and M.-S. Alouini, "Dual Attention-Based Federated Learning for Wireless Traffic Prediction," in *IEEE INFOCOM 2021 – IEEE Conference on Computer Communications*, 2021, pp. 1–10. doi: 10.1109/INFOCOM42981.2021.9488883.

[5] A. Paszke *et al.*, "PyTorch: An Imperative Style, High-Performance Deep Learning Library," in *Advances in Neural Information Processing Systems 32 (NeurIPS)*, 2019, pp. 8024–8035.